Preprocesarea datelor

Preprocesarea datelor este o primă și importantă etapă de pregătire a datelor brute și de a le face potrivite pentru un model de învățare automată. Când se creează un proiect de învățare automată, pentru operațiile cu date este obligatoriu ca acestea să fie nealterate și formatate, ceea ce nu se întâlnește în situații reale. În acest scop, se folosesc operațiile de preprocesare a datelor. Acesta este un prim pas în procesul de analiză a datelor care preia datele brute și le transformă într-un format care poate fi înțeles și analizat de computere pentru algoritmii de învățare automată. Este de fapt un proces de pregătire a datelor pentru operațiile complexe care urmează, fiind de fapt prima etapă în procesul clasic de clasificare și interpretare a datelor.

Datele din lumea reală sunt destul de afectate de zgomot și corupte, cu inconsecvențe, informații incomplete și valori lipsă. Bazele și seturile de date sunt agregate din surse diversificate folosind tehnici de depozitare (introducere și memorare) și de data mining. Performanța modelelor de învățare automată depinde de cantitatea, calitatea și diversitatea datelor. Dacă setul de date este redundant, zgomotos sau nesigur, atunci este foarte greu ca un algoritm de învățare automată să ofere performanțe bune.

Procesul complex de prelucrare a datelor cuprinde trei etape principale:

a) Prelucrarea de nivel scăzut (preprocesarea sau prelucrarea primară);

b) Prelucrare de nivel mediu (descrierea, codificarea și condensarea informației prin extragerea trăsăturilor);

c) Prelucrare de nivel înalt (clasificarea, recunoașterea și interpretarea).

Datele (numerice) pot fi de mai multe feluri: monodimensionale (cum ar fi seriile de timp), bidimensionale (imagini) sau multi-dimensionale. După cum s-a precizat, datele brute din lumea reală, care pot fi sub formă de text, imagini, videoclipuri etc., sunt dezordonate. Nu numai că pot conține erori și zgomote, ci adesea sunt incomplete și au un format necorespunzător prelucrării prin tehnici de învățare automată.

După cum se poate vedea și din diagrama următoare (Fig. 1), preprocesarea datelor urmează imediat după colectarea/achiziția brută a datelor.

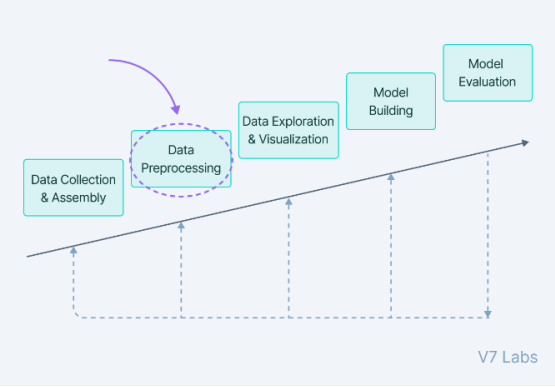


Fig. 1. Localizarea preprocesării datelor.

Operațiile de preprocesare

Aplicarea algoritmilor de extragere a datelor din datele brute care pot fi afectate de zgomot nu ar da rezultate corespunzătoare, deoarece nu ar reuși să identifice și să analizeze modelele în mod corect. Preprocesarea datelor, în particular eliminarea zgomotelor, este importantă pentru a îmbunătăți calitatea generală a datelor. De asemenea, valorile duplicate sau lipsa unor valori din datele achiziționate pot oferi o imagine incorectă a statisticilor generale ale datelor. La fel, valorile aberante și datele inconsecvente tind adesea să perturbe învățarea generală a modelului, ceea ce duce la clasificări sau predicții false.

Operațiile principale de preprocesare a datelor sunt următoarele: curățarea datelor, integrarea datelor, transformarea datelor și reducerea datelor. Sintetic, ele sunt prezentate în Fig. 2.



Fig. 2. Operațiile de preprocesare a datelor.

● **Curățarea datelor** se face în special în prima parte a preprocesării pentru îmbunătățirea prezentării datelor prin operații cum ar fi: completarea valorilor lipsă, netezirea datelor (eliminarea sau reducerea zgomotului), rezolvarea inconsecvențelor și eliminarea valorilor aberante.

● **Integrarea datelor** se bazează pe îmbinarea datelor prezente din mai multe surse într-un singur depozit de date mai mare. Integrarea datelor este necesară mai ales atunci când ne propunem să rezolvăm un scenariu real, cum ar fi detectarea prezenței nodulilor din imaginile CT. Deoarece aceste imagini sunt relativ puține, pentru îmbunătățirea învățării singura opțiune este integrarea imaginilor de la mai multe centre medicale pentru a forma o bază de date mai mare.

● **Transformarea datelor/atributelor** poate fi făcută dacă se obține o reprezentare mai convenabilă a datelor pentru procesul de prelucrare automată.

În cazul transformării valorilor în atribut pot exista următoarele cazuri:

- Numeric -> nominal/ordinal (ex. valoarea vârstei este transformată într-o categorie: foarte tânăr, tânăr, bătrân, foarte bătrân);

- Nominal -> logic/binar (ex. fiecărei valori posibile a unui atribut nominal i se asociază un atribut binar).

Normalizarea este o tehnică importantă de transformare a datelor utilizată pe scară largă. Atributele numerice sunt mărite sau reduse pentru a se încadra într-un interval specificat, dezvoltând astfel o corelație mai bună între diferite valori ale datelor. Există mai multe metode de normalizare în funcție de cerințele concrete ale aplicațiilor.

● **Reducerea datelor** - Dimensiunea setului de date dintr-un depozit de date poate fi prea mare pentru a fi gestionată de diferiți algoritmi de analiză și extragere a datelor. O soluție posibilă este obținerea unei reprezentări reduse a setului de date, care este mult mai mică ca volum, dar care produce aceeași calitate a rezultatelor analitice. Această tehnică își propune să reducă numărul de caracteristici redundante pe care le considerăm în algoritmii de învățare automată. De exemplu, selecția atributelor (ignoră atributele irelevante, redundante sau inconsistente) contribuie la o reprezentare mai eficientă a datelor, prin reducerea volumului de reprezentare. Reducerea dimensionalității se poate face folosind tehnici precum analiza componentelor principale etc.

Seturile mari de date influențează performanța învățării profunde (deep learning). Performanța modelului de sistem „care trebuie să învețe” (de exemplu, o rețea neuronală) poate fi îmbunătățită prin adăugarea de date noi (augmentarea datelor) pentru echilibrarea claselor (în cazul în care acestea sunt debalansate sau au prea puține date). În cazul imaginilor (cazul cel mai frecvent), augmentarea datelor constă într-o serie de operații pentru crearea de imagini noi asemănătoare cu cele existente (de exemplu, prin rotație, translație, contrast, iluminare, zgomot etc.), păstrând evident eticheta clasei. Această operație rezolvă două provocări importante pentru cercetători: a) generează mai multe date dintr-o cantitate limitată de date necesare pentru o învățare eficientă și, b) reduce supraadaptarea clasificatorilor inteligenți, permițând un număr mai mare de clasificări corecte în situații reale.

În practică, cantitatea și calitatea datelor de învățare (în special, de antrenare a rețelelor neuronale) ar trebui să fie suficiente pentru a asigura o fiabilitate și o performanță mai bune ale modelelor complexe de învățare automată. Tehnicile de augmentare a datelor pot fi aplicate ca o soluție relativ simplă de rezolvare a problemei deficitului de date. Ideea principală a augmentării datelor este de a genera date sintetice care au distribuții similare cu datele reale. Datele sintetice pot fi apoi integrate cu datele reale pentru a îmbunătăți performanța de generalizare a modelelor de predicție bazate pe date. Tehnicile de augmentare a datelor au fost utilizate pe scară largă în domeniul vederii artificiale. Datele augmentate ar trebui să fie mai puțin utilizate în fazele de validare și de testare și mai mult în faza de învățare.

Metodele bazate pe transformări afine, cum ar fi rotația, deformarea în timp, scalarea și deplasarea, sunt tehnici convenționale de augmentare a datelor pentru serii de timp. Astfel de metode pot crea noi eșantioane de date prin introducerea de variație suplimentară în datele din seria temporală existentă. Operațiile de rotație pot fi aplicate pentru a crea secvențe sintetice prin inversarea semnelor fără a modifica magnitudinea datelor.

Metodele bazate pe transformare afină sunt cele mai folosite în augmentarea datelor. Dar diversitatea datelor introduse de aceste metode este destul de limitată. Pentru a depăși acest neajuns, au fost propuse tehnici avansate de augmentare a datelor bazate pe rețele neuronale generative. În comparație cu tehnicile convenționale de augmentare, modelele generative pot produce date sintetice cu variații mai largi și de calitate superioară. Rețelele generativ adversare (adică GAN) și autoencoderele variaționale (adică VAE) sunt două metode puternice de modelare generativă bazate pe rețele neuronale artificiale.

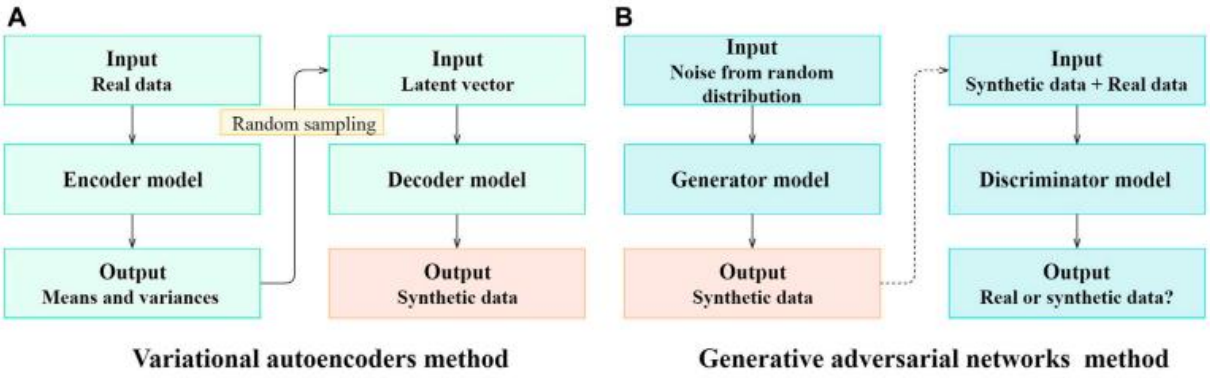


Fig. 3. Rețele neuronale de generare a datelor sintetice.

1. Preprocesarea seriilor de timp

Realizările particulare ale proceselor discrete în timp se numesc serii de timp. Seriile de timp sunt secvențe de observații uniform distanțate, înregistrate la un interval de timp specificat. Astfel de semnale pot proveni direct din procesele reale sau pot proveni din eșantionarea unor semnale analogice ale proceselor reale. În contextul procesării semnalului, un semnal se referă la orice formă de informație care variază în timp sau spațiu. Semnalele pot lua multe forme, variind de la forme de undă audio și valori de temperatură până la date de pe piața financiară și măsurători ale senzorilor.

Există diferite domenii (proveniențe) ale seriilor de timp:

- Senzori – de exemplu, mărimi de mediu (temperatură, presiune, umiditate);
- Date medicale – de exemplu, electrocardiograma, electroencefalograma;
- Indecși financiari;
- Vizite ale unor pagini web.

Reprezentarea seriilor de timp se face, de regulă, prin vectori.
Exemplu – temperatură medie zilnică în grade C în decurs de o săptămână: [21, 23, 22, 19, 19, 20, 21].

Un alt exemplu de serie de timp este prețul aurului. În acest caz, observația se referă la prețul aurului colectat pe o perioadă de timp după intervale de timp fixe. Unitatea de timp poate fi în minute, ore, zile, ani etc., iar diferența de timp dintre oricare două mostre consecutive va fi aceeași.

Datele din seria temporală dețin o mulțime de informații, dar, în general, nu sunt vizibile. Problemele comune asociate cu seriile de timp sunt marcajele temporale neordonate, valorile lipsă (sau marcajele temporale), valorile aberante și zgomotul din date. Dintre toate problemele menționate, gestionarea valorilor lipsă este cea mai dificilă deoarece metodele convenționale de imputare (tehnica utilizată pentru a avea grijă de datele lipsă prin înlocuirea valorilor lipsă pentru a reține majoritatea informațiilor) nu sunt aplicabile în timpul lucrului cu datele din seria temporală.

Structurarea seriilor temporale

Datele din seria temporală se găsesc în general în formate nestructurate, adică marcajele temporale pot fi amestecate și nu sunt ordonate corect. De asemenea, de cele mai multe ori, coloana dată-oră are tipul implicit de date șir și este esențial să se convertească coloana date-timp în tipul de date dată-oră înainte de a-i aplica orice operație.

Semnalele sunt adesea înțelese cel mai bine prin diagrame care sunt utilizate în general pentru diferite tipuri de date. Diagramele sunt o modalitate simplă, dar puternică de a vizualiza datele semnalului, unde axa *y* reprezintă valoarea semnalului, iar axa *x* corespunde unei metrici secvențiale, cum ar fi timpul, sau numărul eșantionului. Aceste diagrame pot oferi o înțelegere imediată a tendințelor și fluctuațiilor. O altă vizualizare comună este o spectrogramă sau o audiogramă.

Completarea/tratarea valorilor neuniforme sau lipsă în seria temporală

Preprocesarea datelor este un pas crucial în procesarea semnalului, ce pune bazele unei analize precise și semnificative. În funcție de date și analiză, acest lucru poate însemna tratarea datelor neuniforme sau lipsă prin metode de reeșantionare și interpolare sau netezirea datelor folosind diferite filtre.

Reeșantionarea este o tehnică care se poate utiliza pentru a standardiza intervalele de date. Poate implica supraeșantionare (creșterea frecvenței datelor) sau downsampling (scăderea frecvenței datelor) pentru a obține o serie de timp regulată.

Interpolarea este o tehnică folosită în mod obișnuit pentru completarea valorii lipsă a seriilor de timp. Gestionarea valorilor lipsă din datele seriei de timp este o sarcină dificilă. Tehnicile convenționale de completare nu sunt aplicabile pentru datele din seria temporală, deoarece contează succesiunea în care sunt primite valorile. Pentru a rezolva această problemă, avem următoarele metode de interpolare:

- Interpolare liniară
- Interpolare spline
- Interpolare bazată pe timp

Exemplu:

Se pot observa următoarele grafice pornind de la datele inițiale cu valori lipsă înainte de interpolare (Fig. 4a), datele interpolate fără marcajul interpolării (Fig. 4b), datele inițiale cu marcajul lipsei (Fig. 4c) și datele interpolate cu marcajul interpolării (Fig. 4d).

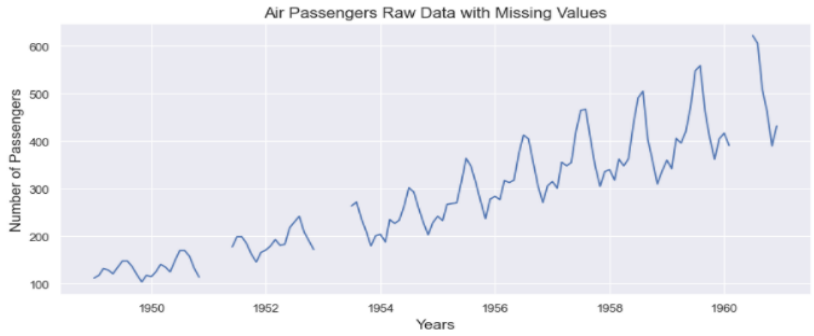


Fig. 4a. Datele inițiale fără marcajul lipsei.

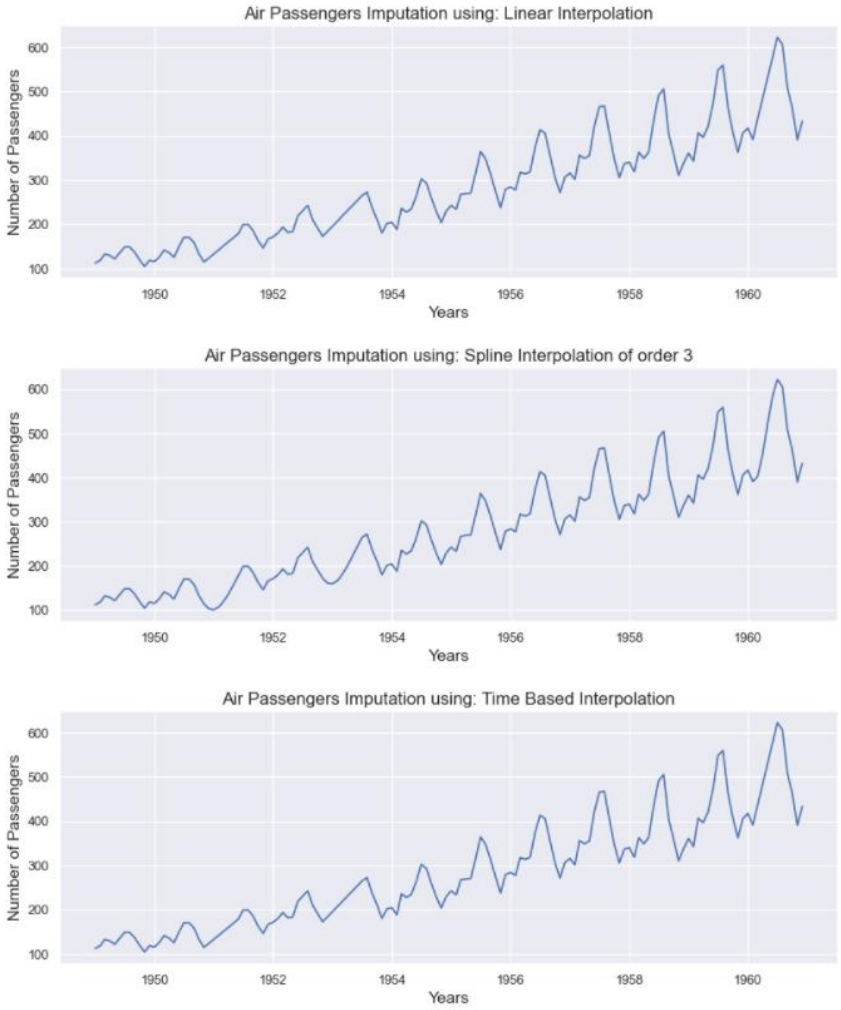


Fig. 4b. Datele interpolate fără marcajul interpolării.

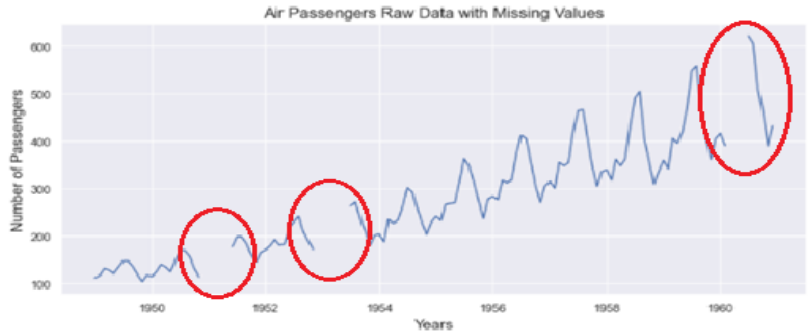


Fig. 4c. Datele inițiale cu marcajul lipsei.

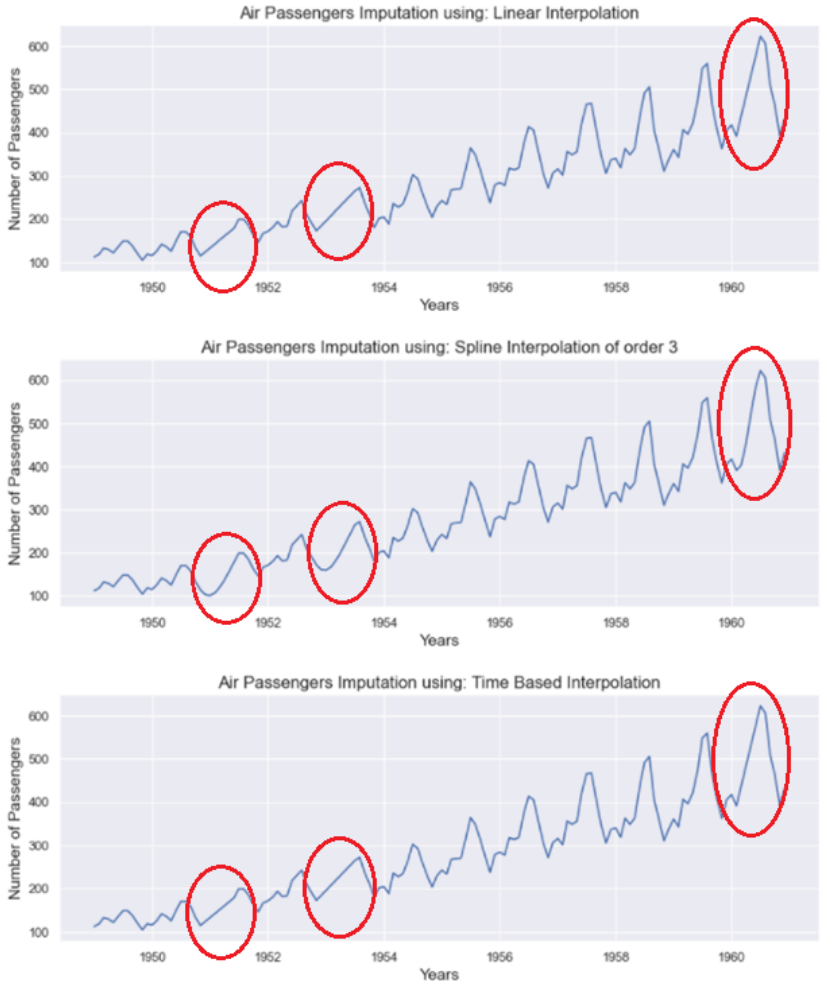


Fig. 4d. Datele interpolate cu marcajul interpolării.

Toate metodele au oferit un set sigur de completări. Aceste metode au mai mult sens atunci când fereastra valorii lipsă (lățimea datelor lipsă) este mică. Dacă numărul valorilor lipsă consecutive este mai mare, atunci este mai dificil ca aceste metode să estimeze lipsurile.

Eliminarea (reducerea) zgomotului unei serii temporale

Zgomotul dintr-o serie temporală poate cauza probleme dificile, iar eliminarea zgomotului este recomandată înaintea altor operații de prelucrare a datelor. Procesul de minimizare a zgomotului uneori se numește netezire.

Următoarele sunt câteva metode utilizate în mod obișnuit pentru eliminarea zgomotului dintr-o serie de timp:

1. Media alunecătoare

Media alunecătoare este media pentru o fereastră anterioară de observații, fereastra fiind o secvență de valori din datele seriei temporale. Media este calculată pentru fiecare fereastră considerată și înlocuiește valoarea din centrul ferestrei cu valoarea medie. Acest lucru poate ajuta foarte mult la minimizarea zgomotului în datele din seria temporală.

Exemplu de aplicație a mediei alunecătoare raportat la prețul acțiunilor Google (Fig. 5):



Fig. 5. Exemplificare privind eliminarea zgomotului cu medie alunecătoare.

2. Filtre active

Sunt tehnici de filtrare bazate pe frecvență utilizate pentru a trece sau a bloca anumite componente de frecvență ale unui semnal (Fig. 6).

Un filtru „trece – jos", permite trecerea semnalelor de joasă frecvență în timp ce atenuează componentele de frecvență mai înaltă, ceea ce îl face util pentru eliminarea zgomotului. Semnalele cu frecvențe mai mari decât frecvența de tăiere sunt atenuate foarte puternic.

În schimb, un filtru „trece – sus" permite trecerea semnalelor de frecvență mai înaltă, eliminând componentele de frecvență joasă. Filtrele de frecvență înaltă sunt adesea folosite pentru a evidenția evenimente de scurtă durată sau schimbări bruște în seria temporală. Semnalele cu frecvenţe mai mici decât frecvența de tăiere sunt atenuate foarte puternic.

Un filtru „trece – bandă" permite semnalelor dintr-o anumită bandă de frecvență să treacă în timp ce blochează altele. Acest tip de filtru este util în aplicațiile în care anumite intervale de frecvență conțin informații relevante. De exemplu, în procesarea audio, un filtru trece – bandă

poate fi folosit pentru a extrage anumite frecvențe corespunzătoare vorbirii umane. Semnalele cu frecvenţe aflate în afara benzii de trecere sunt atenuate foarte puternic.

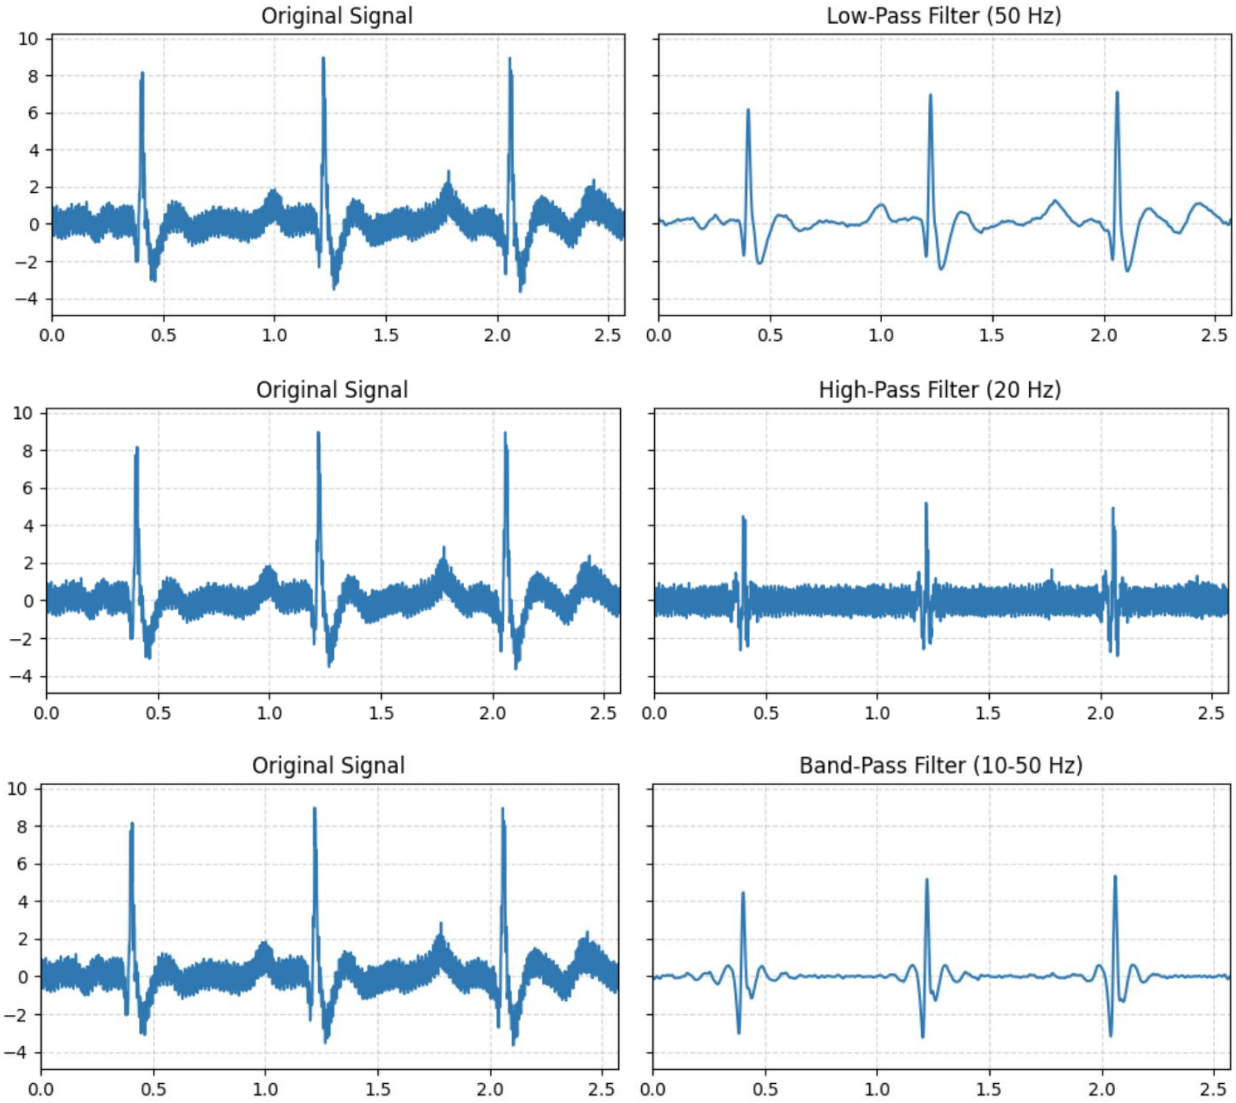


Fig. 6. Exemplificarea modului în care diferitele tipuri de filtre sunt aplicate pe un semnal.

3. Transformata Fourier

Transformarea Fourier poate ajuta la eliminarea zgomotului prin conversia datelor din seria temporală în domeniul frecvenței și, de acolo, putem filtra frecvențele zgomotoase (frecvențele mai mari). Apoi, putem aplica transformata Fourier inversă pentru a obține seria temporală filtrată. Ca exemplu, se poate aplica folosind transformarea Fourier referitor la prețul acțiunilor Google (Fig. 7).



Fig. 7. Exemplificare privind eliminarea zgomotului cu ajutorul transformatei Fourier.

4. Detectarea valorilor aberante în serii temporale

Valorile aberante sunt date care se abat semnificativ de la modelul general, și pot fi gestionate prin tehnici precum trunchierea datelor sau winsorizarea, care implică limitarea unor valori extreme la un anumit prag. O valoare anormală în seria temporală se referă la un vârf (Fig. 8) sau o scădere bruscă a curbei de tendință. Metodele disponibile pentru detectarea valorii aberante:

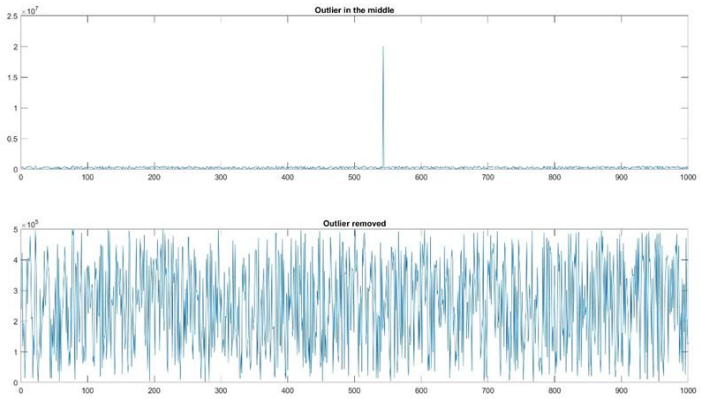


Fig. 8. Eliminarea unei valori aberante din afara unui anumit interval de amplitudine.

Abordare bazată pe limite statistice alunecătoare

Această metodă este cea mai intuitivă și funcționează pentru aproape toate tipurile de serii cronologice. În această metodă, limitele superioare și inferioare sunt create pe baza unor măsuri statistice specifice, cum ar fi media și abaterea standard (de ex. intervalul de încredere $[m_v - 3\sigma, m_v + 3\sigma\ ]$), scorurile Z și T.

Luarea mediei și a abaterii standard a întregii serii nu este recomandabilă pentru detectarea valorii aberante, deoarece limita ar fi statică în acest caz. Limitele ar trebui să fie create pe o bază continuă, cum ar fi luarea în considerare a unui set continuu de observații pentru a crea limite și apoi trecerea la o altă fereastră. Cu toate acestea, este o metodă simplă pentru detectarea valorii aberante.

Când se impune preprocesarea seriilor de timp:

- Lipsa unor valori corespunzătoare unor momente de timp de înregistrare a datelor. Valoarea lipsă este înlocuită prin interpolare (de exemplu – interpolarea liniară între două puncte y_i și y_{i+1}):

$$y = y_i + \frac{t - t_i}{t_{i+1} - t_i}(y_{i+1} - y_i)$$

- Existența zgomotului - fluctuații aleatorii ale datelor care pot ascunde modelele subiacente.

Exemple de zgomot - reprezentare continuă (Fig. 9).

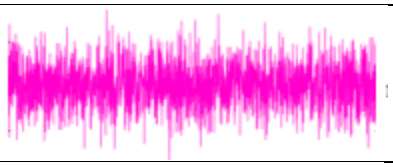
	Zgomot alb, surse: zgomot de la echipament termal, zgomot de fond, zgomot aleator
	Zgomot de tip bandă îngustă, surse: comunicații radio
	Zgomot de tip impuls, surse: acțiune comutator, pornire echipament electric

Fig. 9. Exemple de zgomote ale semnalelor monodimensionale continue.

5. Netezire prin medii alunecătoare

Fie seria de timp finită

$$[x(0), x(1), x(2),..., x(n-2), x(n-1), x(n)]$$

Filtrul bazat pe valoarea medie (alunecătoare) de dimensiune 2k+1, k<<n, înlocuiește valoarea centrală a ferestrei de dimensiune 2k+1, x(i)

$$[x(i-k), x(i-k+1), ..., x(i),..., x(i+k-1), x(i+k)]]$$

cu

$$x'(i) = \frac{1}{2k+1} \sum_{j=i-k}^{i+k} x(j)$$

Evident, fereastra nu poate depăși limitele seriei de timp.

Exemplu de serie de timp de tip treaptă afectată de două puncte de zgomot de tip impuls și filtru bazat pe valoare medie alunecătoare de dimensiune 3 (k=1). Formula filtrului:

$$x'(i) = \frac{1}{3} \sum_{j=i-1}^{i+1} x(j)$$

Seria de timp inițială (cele două puncte de zgomot – roșii)

[0, 0, 0, 0, 0, 0, 0, **9**, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 9, 9, 9, 9, 9, 9, **0**, 9, 9, 9, 9, 9, 9, 9, 9, 9]

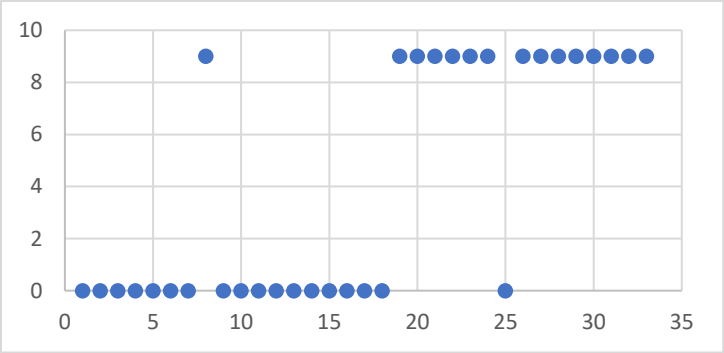


Fig. 10. Seria de timp inițială.

Seria de timp filtrată
[0, 0, 0, 0, 0, 0, **3, 3, 3**, 0, 0, 0, 0, 0, 0, 0, 0, 0, **3, 6**, 9, 9, 9, 9, **6, 6, 6**, 9, 9, 9, 9, 9, 9, 9, 9]
Se observă că zgomotul nu a fost eliminat, ci doar netezit (roșu), iar aspectul de treaptă a fost deformat (albastru).

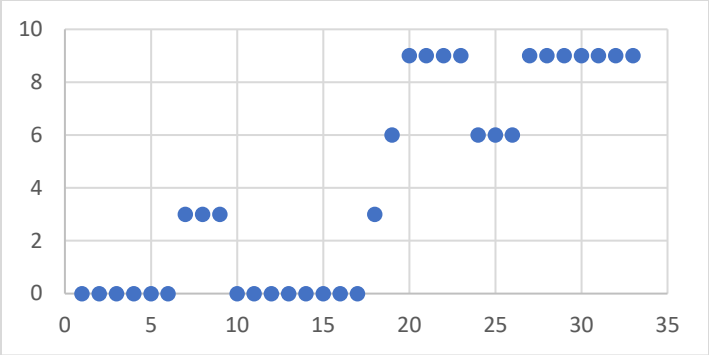


Fig. 11. Seria de timp filtrată cu filtrul bazat pe valoarea medie.

6. Eliminarea zgomotului prin filtru median

Filtrul bazat pe mediană (filtrul median) de dimensiune 2k+1, k<<n, înlocuiește valoarea centrală a ferestrei de dimensiune 2k+1, x(i) cu mediana valorilor din vecinătate:

$$x'(i) = Me\{x(i-k), \dots, x(i), \dots, x(i+k)\}$$

Trecând seria de timp inițială prin filtrul median de dimensiune 3, se observă că zgomotul a fost eliminat, iar forma de semnal treaptă s-a păstrat:

[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9]

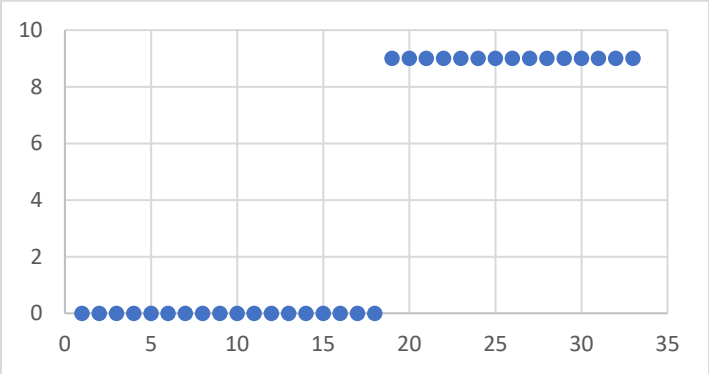


Fig. 12. Seria de timp filtrată cu filtrul median.

Această observație este valabilă doar pentru zgomotul de tip impuls.

7. Data binning (gruparea datelor într-un interval mic, dat)

Se utilizează pentru diverse operații de preprocesare cum ar fi: construirea histogramelor de date (în special pentru volum mai mare de date), filtrarea locală a zgomotului (în interiorul bin-ului) sau reducerea dimensionalității datelor.

Există două metode importante de binning:

1. Binning cu lațime egală - Reordonarea datelor și gruparea lor în intervale de lungime dată – acesta este utilizată la alcătuirea histogramei cu date grupate.
2. Binning cu frecvență egală - Gruparea datelor originale în intervale având aceeași frecvență de apariție.

1. Binning cu lățime egală - este o tehnică de extragere a datelor care împarte valorile (unei variabile) în compartimente de lățimi sau intervale egale. Această abordare are ca scop gruparea valorilor de date în compartimente cu același interval sau aceeași lățime.

Exemplu de binning cu lățime egală:

Se dau următoarele date: [10, 20, 15, 51, 54, 31, 46, 34, 53, 18, 41]

Pasul 1: Se sortează setul de date în ordine crescătoare: [10, 15, 18, 20, 31, 34, 41, 46, 51, 53, 54].

Pasul 2: Se determină lățimea fiecărui interval folosind formula: **w = (max-min) / N**, unde w este lățimea, max este valoarea maximă, min este valoarea minimă și N este numărul de intervale.

În exemplul propus, valoarea minimă este 10, valoarea maximă este 54 și se propune alegerea a patru intervale. Deci, lățimea (w) este calculată ca (54 - 10) / 4 = 11. Acum trebuie adăugată valoarea fiecărui bin care ar fi după cum urmează:

BIN 1: [limita inferioară, limita superioară] = [(min), (min + w -1)] = [10, 20]
BIN 2: [limita inferioară, limita superioară] = [(min + w), (min + 2w -1)] = [21, 31]
BIN 3: limita inferioară, limita superioară] = [(min + 2w), (min + 3w -1)] = [32, 42]
BIN 4: [limita inferioară, limita superioară] = [(min + 3w), (max)] = [43, 54]

Deci, fiecare bin ar conține valori între limita sa inferioară și limita sa superioară. Deci, bin-ul final pentru acest set de date ar avea valori precum:

BIN 1: [10, 15, 18, 20]
BIN 2: [31]
BIN 3: [34, 41]
BIN 4: [46, 51, 53, 54]

2. Binning cu frecvență egală - o tehnică de împărțire a datelor care împarte valorile în compartimente cu un număr egal de observații sau frecvență. Scopul acestei metode este de a se asigura că fiecare bin are o cantitate dată de valori. Acest lucru ajută la reprezentarea informațiilor într-un mod echilibrat.

Exemplu de binning cu frecvență egală:

Se dau următoarele date: [10, 15, 18, 20, 31, 34, 41, 46, 51, 53, 54, 60]

În primul rând, trebuie ca datele să fie sortate. Dacă există date nesortate, trebuie convertite în date sortate și apoi se aplică al doilea pas. În al doilea pas, trebuie să găsim frecvența. Pentru a calcula frecvența, se poate folosi formula: numărul total de puncte de date/numărul **de bins**.

În acest caz, numărul total de puncte de date este 12, iar numărul de bins-uri necesare este 3. Prin urmare, frecvența este 4 și mai rămân de adăugat valori în bins.

BIN 1: 10, 15, 18, 20
BIN 2: 31, 34, 41, 46
BIN 3: 51, 53, 54, 60

Cu alte cuvinte, binning-ul este cunoscut și ca tehnică de discretizare. Discretizarea este o tehnică de preprocesare a datelor utilizată în învățarea automată pentru a transforma caracteristicile continue în unele discrete.

8. One-hot encoding

One-hot encoding este o tehnică puternică în domeniul preprocesării datelor și al ingineriei trăsăturilor. Joacă un rol crucial în conversia variabilelor categorice într-un format care poate fi ușor interpretat de algoritmii de învățare automată. Este folosită pentru conversia datelor categoriale în format binar pentru a fi procesate eficient de modelele de învățare automată. One-hot encoding este un proces de reprezentare a variabilelor categorice ca vectori binari. Aceasta creează noi coloane binare pentru fiecare categorie unică din variabila originală și atribuie 1 sau 0 pentru a indica prezența sau absența unei categorii. Această tehnică este utilă în special atunci când se lucrează cu modele de învățare automată care necesită intrări numerice.

Când o variabilă categorică este codificată cu o singură valoare, fiecare categorie este transformată într-un vector binar în care toate elementele sunt zero, cu excepția elementului corespunzător categoriei, care este setat la unu. Această transformare permite modelului să înțeleagă și să diferențieze între diferite categorii fără a presupune nicio relație ordinală între ele.

Numărul de dimensiuni corespunde numărului de categorii, iar fiecare categorie primește dimensiunea sa. Apoi, se codifică fiecare categorie mapând-o la un vector în care elementul corespunzător dimensiunii categoriei este 1, iar restul sunt 0.

De exemplu, dacă se presupune că variabila categorială denotă predicția vremii și are trei categorii: soare, ploaie și vânt. Atunci, codificarea este: soare = [1, 0, 0], ploaie = [0, 1, 0], vânt = [0, 0, 1].

2. Preprocesarea imaginilor

a. Reprezentarea imaginilor

O *imagine numerică* (monocromă sau alb – negru, cu nuanțe de gri) este caracterizată prin funcția *G*, (1):

$$G : M_1 \times M_2 \to N \tag{1}$$

unde $M_1 \subset N$, $M_2 \subset N$, N fiind mulțimea numerelor naturale.

$M_1 = \{0,1,\ldots,n_1 - 1\}$, $M_2 = \{0,1,\ldots,n_2 - 1\}$

Perechea $(n_1, n_2) \overset{not}{=} n_1 \times n_2$ se numește *dimensiunea imaginii*.

Definiție:

Un element de imagine denumit în continuare *pixel* este un triplet:

$$E_{i,j,G} = \{i, j, G(i,j)\}, i \in M_1, j \in M_2$$

Perechea (i,j) este **poziția pixelului**, iar $G(i,j)$ este **valoarea (nivelul de gri) pixelului**.

Imaginea numerică se poate reprezenta prin matricea [G] de dimensiune $n_1 \times n_2$ (2).

$$[G] = \begin{bmatrix} G(0,0) & G(0,1) & G(0,n_2-1) \\ G(1,0) & G(1,1) & G(1,n_2-1) \\ \dots & \dots & \dots \\ G(n_1-1,0) & \dots & G(n_1-1,n_2-1) \end{bmatrix} \quad (2)$$

Imaginile color se pot reprezenta, în domeniul original, spațial, printr-un set de trei matrice, $[G_R]$, $[G_G]$, $[G_B]$, de aceeași dimensiune, corespunzând ponderilor culorilor fundamentale (R – roșu, G – verde si B – albastru) în alcătuirea pixelilor color (3). Aceștia vor avea cinci elemente:

$$E_{i,j,R,G,B} = \{i, j, G_R(i,j), G_G(i,j), G_B(i,j)\}, i \in M_1, j \in M_2 \quad (3)$$

În cele ce urmează, pentru simplificarea expunerii, vom considera imaginile numerice ca fiind monocrome.

Originea imaginii se ia în colțul din stânga sus al axelor de coordonate (Fig. 13) și poate fi considerată (0,0) .

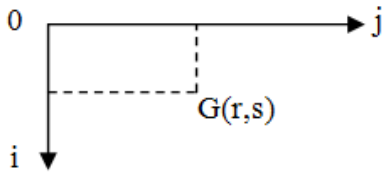


Fig. 13. Sistemul de axe al imaginii.

b. Reducerea zgomotului din imagini

Zgomotul de imagine apare ca urmare a unor procese nedorite care se manifestă în timpul achiziționării semnalului util. În cazul imaginilor, este vorba de variații ale sensibilității senzorilor, variații ale mediului, natura discretă a radiației luminoase, erori de transmisie sau de cuantizare etc.

Eliminarea sau reducerea zgomotului din imagine este prima operație de prelucrare primară ce trebuie efectuată asupra unei imagini, deoarece zgomotul poate fi amplificat de prelucrările ulterioare, cum ar fi îmbunătățirea contrastului.

Principalul tip de zgomot care apare în imagini este zgomotul gaussian. Acesta poate fi redus prin utilizarea unui filtru de tip trece-jos. Din această cauză, prin netezire nu se reduc doar zgomotul, ci și detalii ale imaginii. De regulă, pentru reducerea zgomotului de imagine se folosesc filtre locale (acționând în vecinătatea pixelului considerat), deoarece au o comportare mai bună față de liniile de contur decât cele globale.

A. Filtre bazate pe valoarea medie

Filtrul bazat pe valoarea medie înlocuiește valoarea nivelului de gri în punctul (*i,j)* cu valoarea medie pe o vecinătate $(2h+1)\times(2h+1)$ a punctului respectiv (4):

$$G'(i,j)=\frac{1}{(2h+1)^2}\sum_{m=-h}^{h}\sum_{n=-h}^{h}G(i+m,j+n),$$
$$i=\{h,h+1,...,n_1-1-h\}\ ;\ j=\{h,h+1,...,n_2-1-h\} \tag{4}$$

De regulă, $h = 1$, deoarece o creștere a ferestrei de mediere conduce la estomparea liniilor de contur și la apariția neclarităților. Astfel, dacă notăm fereastra:

$$\begin{bmatrix} G(i-1,j-1) & G(i-1,j) & G(i-1,j+1) \\ G(i,j-1) & G(i,j) & G(i,j+1) \\ G(i+1,j-1) & G(i+1,j) & G(i+1,j+1) \end{bmatrix}=\begin{bmatrix} a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \\ c_1 & c_2 & c_3 \end{bmatrix} \tag{5}$$

punctul central b_2 este înlocuit cu b_2' având expresia:

FM: $$b_2'=\frac{1}{9}(a_1+a_2+a_3+b_1+b_2+b_3+c_1+c_2+c_3) \tag{6}$$

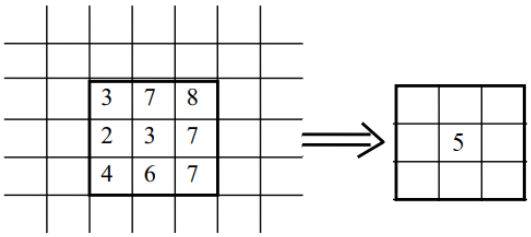


Fig. 14. Exemplu de calcul al filtrului bazat pe valoare medie într-o fereastră pătrată de 3×3.

B. Filtrul bazat pe valoarea mediană (filtru median)

Filtrul median înlocuiește valoarea centrală $G(i,j)$ cu mediana valorilor dintr-o vecinătate simetrică, de dimensiune $(2h+1)\times(2h+1)$, centrată în punctul (i,j). Se obțin rezultate asemănătoare cu cele ale cazului monodimensional, și anume că filtrul median bidimensional păstrează liniile de pe contur și zonele constante mai mari decât fereastra și elimină zgomotele de tip impuls. Ca vecinătăți pentru filtrul median se folosesc vecinătăți simetrice de n puncte (cu n impar), ca în exemplele din Fig. 15.

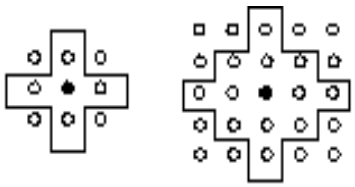


Fig. 15. Vecinătăți simetrice pentru filtrul median bidimensional
stânga: $n = 5$ puncte; dreapta: $n = 13$ puncte.

Astfel, pentru vecinătatea de 5 puncte, funcția filtrului median este următoarea:

$$\text{FMe:} \qquad b_2^{'} = Me\{a_2, b_1, b_2, b_3, c_2\} \tag{7}$$

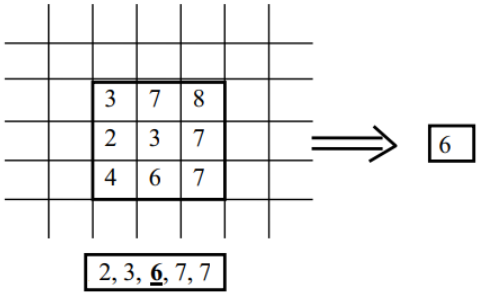


Fig. 16. Exemplu de calcul al medianei într-o fereastră pătrată de 3×3.

C. Filtrul de netezire logică

Un caz important, care apare în sistemele de vedere artificială ale roboților industriali, este acela în care $G(i,j)$ este codificată pe un singur bit (imagine binarizată). Atunci, pentru eliminarea zgomotului de tip *sare și piper* (1 între *0* -uri sau *0* între *1*-uri) se pot folosi filtre locale, bazate pe funcții logice (8):

$$\text{FB:} \qquad \begin{aligned} b_2' = &\left[b_2 \cup \left(a_1 \cap a_2 \cap a_3 \cap b_1 \cap b_3 \cap c_1 \cap c_2 \cap c_3\right)\right] \cap \\ &\left(\overline{b}_2 \cup a_1 \cup a_2 \cup a_3 \cup b_1 \cup b_3 \cup c_1 \cup c_2 \cup c_3\right) \end{aligned} \tag{8}$$

Pentru a putea folosi filtrul binar (FB) este necesară binarizarea imaginii. Pragul de binarizare se alege în așa fel încât, prin binarizare, să se detașeze silueta obiectului de fond și imaginea să aibă un zgomot – pixeli alterați – cât mai redus, iar acesta să fie de tip *sare și piper*. Astfel, se obține o imagine având *1* logic pentru pixelii aparținând formei și *0* logic pentru pixelii aparținând fondului.

Algoritmul FB poate fi rezumat astfel:

1. dacă toți vecinii lui b_2 au aceeași valoare, atunci $b_2^{'}$ ia această valoare;
2. dacă nu toți vecinii lui b_2 au aceeași valoare, atunci $b_2^{'} = b_2$ (rămâne neschimbat).

D. Exemple de calcul

Pentru punerea în evidență a algoritmilor de reducere a zgomotului se vor utiliza matrice de dimensiuni reduse.

Se dă imaginea exemplu I_{10} (Fig. 17) în care *0* reprezintă negrul, *9* reprezintă albul, iar valorile intermediare reprezintă nuanțele de gri. Interiorul poligonului se consideră ca fiind obiectul util, iar exteriorul, fondul. Pixelii afectați de zgomot sunt marcați cu cifre italice îngroșate. Pentru filtrarea pixelilor de pe margine, se consideră matricea extinsă prin bordare cu *0*. Pentru utilizarea filtrului binar, se procedează întâi la binarizarea imaginii. Prin utilizarea săgeților, se marchează acțiunea algoritmilor locali menționați anterior, în vecinătățile 3×3. Valorile obținute prin calcul se rotunjesc la cel mai apropiat întreg.

$I_{1,0}=$

0	0	0	0	0	0	0
0	9	9	9	9	9	0
0	9	***0***	9	***0***	9	0
0	9	9	9	9	9	0
0	9	***2***	***3***	9	0	0
0	9	9	9	0	0	0
0	0	0	0	0	0	0

Fig. 17. Exemplu de semnal bidimensional (imagine) afectat de zgomot.

Exemplu: Pentru matricea $I_{1,0}$, transformarea corespunzătoare utilizării filtrului bazat pe valoarea medie FM este prezentată în Fig. 18 ($I_{1,a}$).

Semnificațiile notațiilor (1) şi (2) din Fig. 16 sunt următoarele:

(1): $b_2' = \frac{1}{9}(0+0+0+0+0+0+0+9+0) = 1$

(2): $b_2' = \frac{1}{9}(0+9+0+0+9+9+0+9+2) = \frac{38}{9} \cong 4$

Punctele din fereastra 3×3 corespunzătoare lui (1) reprezintă valoarea 0, de completare.

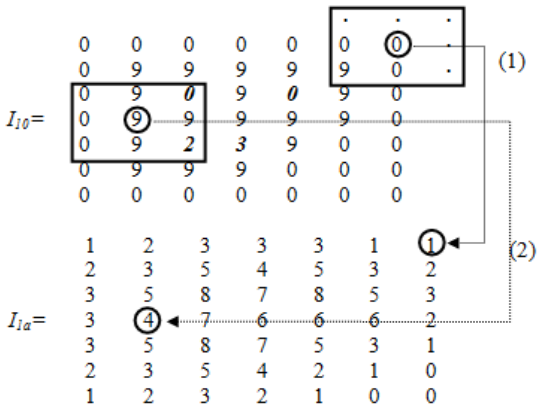


Fig. 18. Exemplificarea modului de acționare a filtrului FM.

Exemplu: Pentru matricea $I_{1,0}$, transformarea corespunzătoare utilizării filtrului bazat pe mediană FMe este prezentată în Fig. 19 ($I_{1,d}$). Semnificațiile notațiilor (7) și (8) din Fig. 19 sunt următoarele:

(7): $b_2' = M_e\{0,0,9,9,9\} = 9$

(8): $b_2' = M_e\{0,0,3,9,9\} = 3$

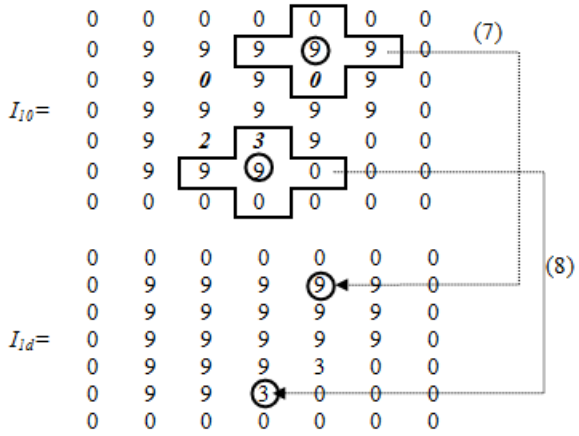


Fig. 19. Exemplificarea modului de acționare a filtrului median de 5 puncte.

Exemplu: Dacă pentru $I_{1,0}$ se alege pragul P = 1, se obține imaginea binarizată I_{bin} având doar două puncte de zgomot: (3,3) și (3,5) - Fig. 20. Aplicând filtrul binar de eliminare a zgomotului, se obține $I_{1,e}$. Semnificația notației (9) este: $b_2' = 1$, deoarece toți vecinii săi sunt 1.

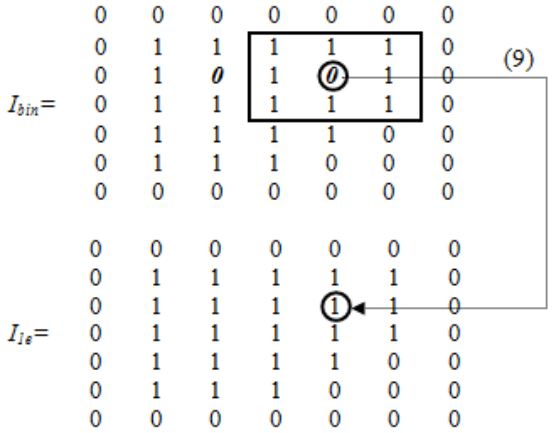


Fig. 20. Exemplificarea modului de acționare a filtrului binar.

Exemplu. Eliminare zgomot de tip „sare si piper” (Fig. 21)



Fig. 21. Exemplificarea eliminării zgomotului cu filtrul median.

c. Prelucrări primare bazate pe histogramă

Histograma unei imagini pe nivele de gri reprezintă frecvența relativă de apariție a nivelurilor de gri din imaginea analizată. Aceasta furnizează o descriere globală a imaginii și ajută la identificarea diferitelor componente, cum ar fi fundalul, diferitele obiecte sau zgomote din imagine.

În Fig. 23 este dată histograma pentru imaginea din Fig. 22.



Fig. 22. Imagine de test.

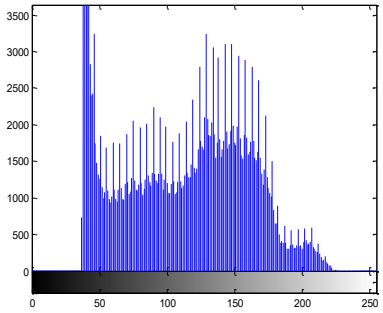


Fig. 23. Histograma imaginii din Fig. 22.

Egalizarea de histogramă

Algoritmul de egalizare a histogramei redistribuie pixelii din imagine pe nivelurile de gri astfel încât toate nivelurile de gri din domeniu să devină, pe cât posibil, egal probabile, adică numărul de pixeli de pe fiecare nivel de gri să fie aproximativ acelaşi pentru toată imaginea prelucrată. Ca urmare, anvelopa graficului histogramei imaginii rezultate în urma prelucrării tinde să fie cât mai apropiată de o linie paralelă cu axa orizontală, adică valoarea funcției histogramei în fiecare nivel de gri din domeniu tinde să fie constantă.

În Fig. 24 este dată histograma după aplicarea algoritmului de egalizare, iar în Fig. 25 este prezentată imaginea rezultată după egalizarea histogramei.

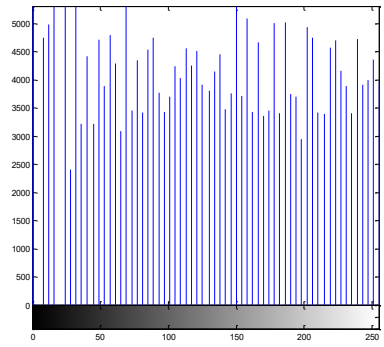


Fig. 24. Histograma egalizată.



Fig. 25. Imaginea rezultată după egalizarea histogramei.

d. Binarizarea imaginilor

Binarizarea imaginilor cu prag fixat

Imaginile obținute în urma binarizării imaginii din Fig. 22 cu diferite praguri fixate de operator este prezentată în Fig. 26. Imaginea inițială are 256 niveluri de gri.



a) b) c)

Fig. 26. Binarizarea imaginii cu praguri diferite: a) T = 63, b) T = 127 și c) T = 191.

Binarizarea cu prag fixat este trivială ca aplicație, deoarece decizia alegerii pragului nu este automată. Totuși descrierea modului de alegere a pragului de binarizare este utilă pentru înțelegerea modului în care binarizarea poate discrimina pe criterii de semnificație.

În Fig. 27 sunt reprezentate imaginea unei piese, versiunea acestei imagini afectată de zgomot de tip gaussian și zgomot de tip sare și piper, precum și histogramele celor două imagini.

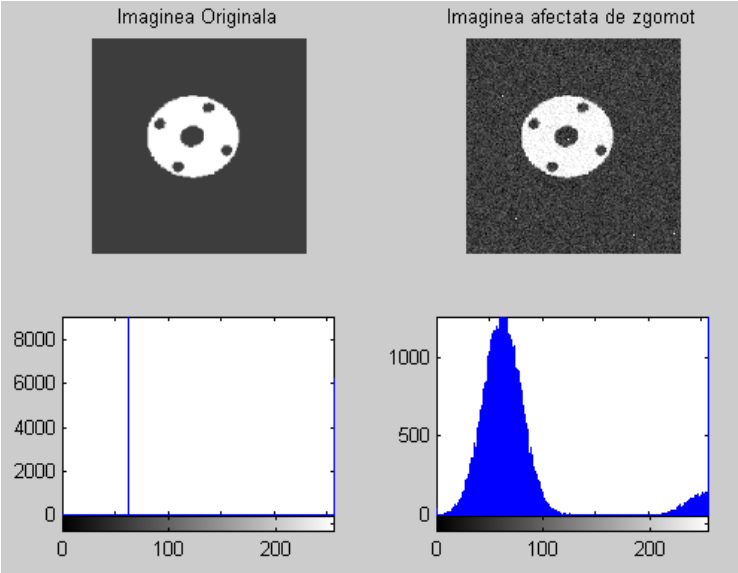


Fig. 27. Imaginea originală a unei piese, versiunea afectată de zgomot și histogramele celor două imagini.

Această situație apare des în aplicații industriale și permite alegerea ușoară a pragului de binarizare: valoarea corespunzătoare minimului dintre cele două puncte de maxim ale histogramei. Modificarea pragului de binarizare poate conduce la rezultate (imagini diferite) – Fig. 28 - 31.

Se observă că pragul $P = 150$ este cea mai bună soluție pentru cazul de față. Totuși, așa cum era de așteptat, zgomotul de tip sare și piper persistă și după binarizare. Pentru reducerea acestuia se poate utiliza un filtru de reducere a zgomotului bazat pe funcții logice.

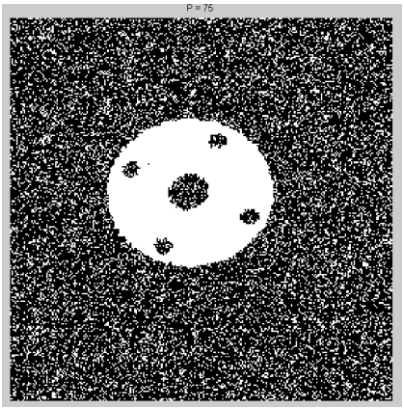


Fig. 28. Binarizare cu pragul $P = 75$.

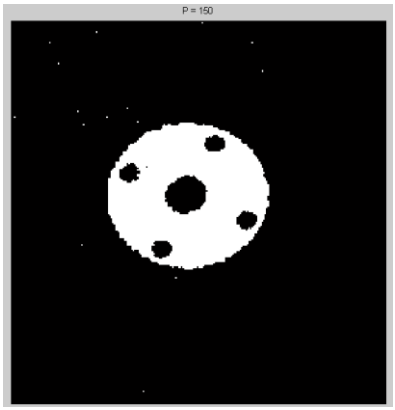


Fig. 29. Binarizare cu pragul $P = 150$.

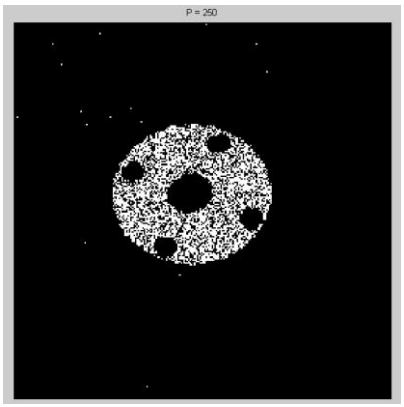


Fig. 30. Binarizare cu pragul $P = 250$.

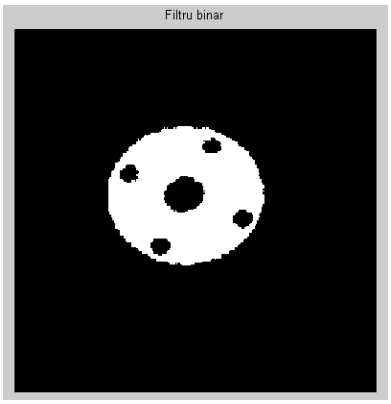


Fig. 31. Rezultatul aplicării filtrului binar.

Binarizarea imaginilor cu prag adaptiv

În condiții de mediu dificile, această metodă dă rezultate mai bune, deoarece ține seama de intensitatea luminoasă într-o vecinătate a punctului considerat. Pentru stabilirea pragului de binarizare $P(i,j)$, se consideră o vecinătate simetrică $V_{i,j}$, de dimensiune $n \times n$, $n = 3 \div 15$. Tehnicile de binarizare cu prag adaptiv determinat local pentru fiecare punct al imaginii se comportă mai bine pe imagini în care intensitatea luminoasă diferă de la o zonă la alta a imaginii. Practic, pentru fiecare pixel se determină valoarea pragului pe baza valorilor dintr-o vecinătate simetrică.

Pentru stabilirea valorii pragului se poate folosi una dintre următoarele mărimi:

- Media aritmetică dintre valoarea maximă și valoarea minimă a nivelului de gri din vecinătatea $V_{i,j}$ (9);
- Media aritmetică a nivelului de gri din vecinătatea $V_{i,j}$ (10);
- Mediana nivelului de gri din vecinătatea $V_{i,j}$, (11);
- Punctul de minim dintre cele două vârfuri ale histogramei nivelului de gri, dacă aceasta este bimodală.

$$P(i,j) = \frac{Max\{G(i,j)\} + \min\{G(i,j)\}}{2} \tag{9}$$

$$P(i,j) = \bar{G}(r,s) \tag{10}$$

$$P(i,j) = \mathrm{Me}\{G(r,s)\} \tag{11}$$

e. Eliminarea zgomotului din imagini binarizate prin operații morfologice

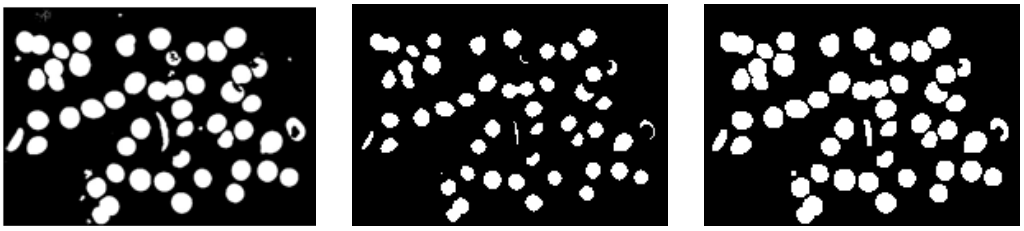
Operațiile morfologice principale sunt dilatarea și eroziunea. Dilatarea mărește obiectele, permițând umplerea unor mici goluri și conectarea obiectelor disjuncte. Eroziunea micșorează obiectele prin erodarea marginilor obiectelor. Aceste operații pot fi adaptate diverselor aplicații prin selectarea elementului structural folosit, care determină modul în care vor fi dilatate sau erodate obiectele. Cum imaginea este binară, fiecare pixel este înlocuit ori cu 0 (alb - fundal), ori cu 1 (negru - obiect). În Fig. 32 este prezentat un exemplu de imagine supusă eroziunii $A \ominus B$ și dilatării $A \oplus B$.

$$\begin{matrix} 0&0&0&0&0\\ 0&1&1&1&0\\ 0&1&1&1&0\\ 0&1&1&1&0\\ 0&0&0&0&0 \end{matrix} \quad A \qquad \begin{matrix} 0&1&0\\ 1&1&1\\ 0&1&0 \end{matrix} \quad B \qquad \rightarrow \qquad \begin{matrix} 0&0&0&0&0\\ 0&0&0&0&0\\ 0&0&1&0&0\\ 0&0&0&0&0\\ 0&0&0&0&0 \end{matrix} \quad A \ominus B$$

$$\begin{matrix} 0&0&0&0&0\\ 0&1&1&1&0\\ 0&1&1&1&0\\ 0&1&1&1&0\\ 0&0&0&0&0 \end{matrix} \quad A \qquad \begin{matrix} 0&1&0\\ 1&1&1\\ 0&1&0 \end{matrix} \quad B \qquad \rightarrow \qquad \begin{matrix} 0&1&1&1&0\\ 1&1&1&1&1\\ 1&1&1&1&1\\ 1&1&1&1&1\\ 0&1&1&1&0 \end{matrix} \quad A \oplus B$$

Fig. 32. Exemplu privind aplicarea tehnicilor de eroziune și dilatare.

Un exemplu de eliminare a zgomotelor prin eroziune și dilatare (imagine microscopică cu celule roșii segmentate) este prezentat în Fig. 33.



a) b) c)

Fig. 33. Exemplu de eliminare a zgomotelor prin metoda morfologică de deschidere (eroziune și dilatare): a) imagine inițială, b) imagine după aplicarea eroziunii, c) imagine după aplicarea dilatării.