Feature Engineering (Ingineria trăsăturilor)

O trăsătură (caracteristică) este o reprezentare numerică a datelor brute. Există multe modalități de a transforma datele brute în reprezentări numerice. Trăsăturile trebuie să derive din tipul de date disponibile. Poate mai puțin evident este faptul că sunt și ele legate de model; unele modele sunt mai potrivite pentru anumite tipuri de trăsături și invers. Trăsăturile alese trebuie să fie relevante pentru aplicația în cauză și ar trebui să fie ușor de introdus în model. Plecând de la *date, model și sarcina* de îndeplinit prin ingineria trăsăturilor, se aleg cele mai adecvate trăsături.

Numărul de trăsături este, de asemenea, important. Dacă nu există suficiente trăsături care să cumuleze informațiile necesare, atunci modelul nu va putea îndeplini sarcina finală. Dacă sunt prea multe trăsături sau dacă majoritatea sunt irelevante, atunci modelul va fi mai general și mai dificil de antrenat. Cu alte cuvinte, trebuie ales un număr minim de trăsături pentru îndeplinirea sarcinii respective.

Ingineria trăsăturilor (sau extragerea trăsăturilor sau descoperirea trăsăturilor) este procesul de utilizare a cunoștințelor dintr-un anumit domeniu pentru a extrage trăsături (caracteristici, proprietăți, atribute) din datele brute. Scopul este acela de a folosi aceste entități (funcții) suplimentare pentru a îmbunătăți performanțele unui proces de învățare automată (calitatea rezultatelor și timpul de operare) față de cazul operării cu datele brute.

Ingineria trăsăturilor făcută de operatorul uman poate fi un proces consumator de timp și predispus la greșeli, deoarece necesită expertiză în domeniu și implică adesea încercări și erori. Rețelele neuronale pot procesa un set mare de date brute, extragerea trăsurilor făcându-se automat în straturile rețelelor. De reținut faptul că înainte de extragerea trăsăturilor este necesară preprocesarea datelor, cu accent deosebit pe curățarea datelor de intrare. De asemenea, alegerea arhitecturii rețelei, a hiperparametrilor și a algoritmilor de optimizare constituie un proces iterativ care nu poate fi neglijat.

Selectarea trăsăturilor este importantă deoarece poate îmbunătăți performanța unui algoritm de învățare automată prin reducerea dimensiunii spațiului trăsăturilor, eliminând trăsăturile cu zgomot, irelevante și redundante. Se urmărește selectarea celor mai relevante și informative trăsături dintr-un anumit set de date.

Extragerea trăsăturilor din imagini

Trăsăturile unei forme (imagine) sunt funcții numerice ce exprimă caracteristici sau proprietăți ale acelei forme și care au rolul de a condensa informația în așa fel încât forma să poată fi reprezentată univoc într-un spațiu de dimensiune mică, numit *spațiul trăsăturilor*. În acest spațiu, forma sau imaginea poate fi clasificată sau interpretată cu un volum de calcul mult mai mic decât dacă s-ar utiliza imaginea inițială. Trăsăturile trebuie să prezinte proprietatea de definire și separare a claselor, în sensul că, pe de o parte, trebuie să ia valori cât mai diferite de la o clasă la alta, iar pe de altă parte să aibă valori cât mai apropiate în cadrul aceleiași clase (proprietatea de grupare).

După natura lor, trăsăturile pot fi: geometrice, funcționale, topologice etc. De asemenea, aceste caracteristici pot fi grupate în funcție de invarianța față de anumite transformări geometrice: trăsături independente de rotație și translație, dependente de rotație, dependente de translație etc. În afară de aceste trăsături, există și trăsături pentru forme speciale, cum ar fi fractalii sau texturile. Pentru rețele neuronale convoluționale, trăsăturile extrase de la un nivel de prelucrare la altul se bazează pe legi combinaționale locale, fiecare nivel de neuroni având o hartă proprie (formată din imagini) a trăsăturilor.

În general, nu există o metodă teoretică, general valabilă, de alegere și utilizare a trăsăturilor în procesul de recunoaștere și clasificare a formelor, această operație fiind dependentă de aplicație și necesitând o serie de etape de testare și validare a rezultatelor. Se urmărește să se obțină performanțe de clasificare cât mai bune (de exemplu, acuratețea) cu un număr cât mai mic de trăsături.

Cazul particular 1. Extragerea trăsăturilor din imagini

Extragerea trăsăturilor geometrice

În continuare, se va prezenta o serie de algoritmi pentru calculul principalelor trăsături geometrice (arie și perimetru).

Determinarea directă a ariei și a perimetrului

Considerând imaginea binarizată, adică:

$$B(i,j) = \begin{cases} 1, \text{ dacă punctul } (i,j) \text{ aparține obiectului,} \\ 0, \text{ dacă punctul } (i,j) \text{ aparține fundalului,} \end{cases}$$

aria A se calculează cu formula (1):

$$A = \sum_{i=0}^{n_1-1} \sum_{j=0}^{n_2-1} B(i,j)\Delta^2 \tag{1}$$

unde $n_1 \times n_2$ reprezintă dimensiunea imaginii, iar Δ este pasul de discretizare spațială.

Observație. Pentru determinarea ariei se numără valorile de 1 întâlnite la baleierea imaginii binarizate, obținându-se o estimare a ei (2), care se consideră, de cele mai multe ori, aria propriu-zisă:

$$A_1 = \sum_{i=0}^{n_1-1} \sum_{j=0}^{n_2-1} B(i,j) \tag{2}$$

Dacă se dispune de conturul formei, dat de un număr finit de puncte

$p_k = (x_k, y_k)$, $k = 1,2, ..., K_0$

aşezate în ordinea vecinului celui mai apropiat, perimetrul formei poate fi determinat prin suma

$$D(p_k, p_{k+1}) = \begin{cases} \Delta \text{ , dacă } p_k \text{ şi } p_{k+1} \text{ sunt pe aceeaşi linie sau coloană,} \\ \Delta\sqrt{2} \text{ , dacă } p_k \text{ şi } p_{k+1} \text{ sunt pe o dreaptă înclinată la } 45^0 \end{cases}$$

unde $D(p_k, p_{k+1})$ reprezintă distanța dintre punctele succesive de pe contur, p_k și p_k+1. S-a considerat conturul închis fără întreruperi.

Se observă că:

$$P_1 = \sum_{k=1}^{K_0} D_1(p_k, p_{k+1}) \quad ; \quad p_{K_0+1} = p_1 ,$$

unde:

$$D_1(p_k, p_{k+1}) = \begin{cases} 1, \text{ dacă } p_k \text{ şi } p_{k+1} \text{ sunt pe aceeaşi linie sau coloană,} \\ \sqrt{2} \text{ , dacă } p_k \text{ şi } p_{k+1} \text{ sunt pe o dreaptă înclinată la } 45^0 \end{cases}$$

Observație. De multe ori, se aproximează perimetrul prin relația de mai sus.

Determinarea coordonatelor centrului de greutate. Calculul razei minime, razei maxime și al razei medii

Presupunând cunoscută aria formei plane A, *coordonatele centrului de greutate* se pot determina cu ajutorul următoarelor relații:

$$i_G = \frac{1}{A_1} \sum_{i=0}^{n_1-1} \sum_{j=0}^{n_2-1} iB(i,j) \quad , \quad j_G = \frac{1}{A_1} \sum_{i=0}^{n_1-1} \sum_{j=0}^{n_2-1} jB(i,j) \tag{3}$$

unde:

$$A_1 = \frac{A}{\Delta^2} = \sum_{i=0}^{n_1-1} \sum_{j=0}^{n_2-1} B(i,j)$$

Produsele din cadrul sumelor duble din (3) pot fi 0, dacă $B(i,j) = 0$, sau i (respectiv, j), dacă $B(i,j) = 1$. Modificând scrierea relațiilor de mai sus, prin punerea în evidență a produselor $A_1 i_G$ și $A_1 j_G$, rezultă expresii mai simple de calculat (4):

$$A_1 i_G = \sum_{B(i,j)=1} i \quad , \quad A_1 j_G = \sum_{B(i,j)=1} j \tag{4}$$

Astfel, coordonatele centrului de greutate (i_G,j_G) se pot determina prin baleierea liniilor şi coloanelor matricei imaginii, potrivit următorului algoritm:

1. Se calculează produsul $A_1 i_G$ prin sumarea repetată a indicelui liniei pixelului (i,j), ori de câte ori valoarea binarizată a nivelului de gri, B(i,j), este 1.

2. În mod analog, se calculează produsul $A_1 j_G$ prin sumarea repetată a indicelui coloanei pixelului (i,j), ori de câte ori valoarea binarizată a nivelului de gri, B(i,j), este 1.

3. Coordonatele centrului de greutate i_G, respectiv jG, se determină prin împărțirea valorilor obținute la punctele 1 și 2 la A_1 (rotunjire la numere întregi).

Raza maximă a formei plane reprezintă distanța maximă de la centrul de greutate al obiectului la conturul exterior. Ea se calculează determinând maximul șirului de distanțe de la centrul de greutate la fiecare punct de pe conturul exterior:

$$R_{\max} = \underset{1 \le k \le K_0}{Max} \{D(G, p_k)\} \tag{5}$$

unde $G = (i_G, j_G)$ este centrul de greutate, iar p_k, $k \in \{1,2, \ldots, K_0\}$, un punct de pe contur; prin $D(G, p_k)$ s-a notat distanța euclidiană dintre G și p_k.

Raza minimă (6) și *raza medie* (7) se definesc analog, prin distanța minimă, respectiv, distanța medie de la centrul de greutate la conturul exterior:

$$R_{\min} = \underset{1 \le k \le K_0}{Min} \{D(G, p_k)\} \tag{6}$$

$$R_{med} = \frac{1}{K_0} \sum_{k=1}^{K_0} \{D(G, p_k)\} \tag{7}$$

Exemplu

Aria și perimetrul vor fi evaluate în pixeli pe o matrice 7×7 și vor fi notate prin A și, respectiv, prin P.

Se consideră imaginea binarizată (forma) din Fig. 1:

$$Ib = \begin{matrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{matrix}$$

Fig. 1. Imagine binarizată.

Să se calculeze:

a. Aria și perimetrul folosind metode de numărare directă a pixelilor.
b. Coordonatele centrului de greutate.
c. Razele: minimă, maximă și medie.

Rezolvare

a. Prin calcul direct, folosind relațiile anterioare și considerând imaginea binarizată (Fig. 1) și imaginea contur (Fig. 2), rezultă:

$$A = 22, \qquad P = 12 + 2\sqrt{2}$$

$$Ic = \begin{matrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{matrix}$$

Fig. 2. Imagine contur.

b. Pentru determinarea centrului de greutate al formei (3) din aceeași imagine (I_{bin}) se consideră originea colțul din stânga sus al imaginii: $i = 0$, $j = 0$. Grupând indicii liniilor și, respectiv, ai coloanelor, se obțin următoarele rezultate:

$$iB(i,j) = 5\times1 + 5\times2 + 5\times3 + 4\times4 + 3\times5 = 61,$$

$$jB(i,j) = 5\times1 + 5\times2 + 5\times3 + 4\times4 + 3\times5 = 61,$$

$$i_G = \frac{61}{22} \cong 3; \qquad j_G = \frac{61}{22} \cong 3$$

Rezultatul este:

Coordonatele centrului de greutate sunt: *ig*=3.7727 *și jg*=3.7727

c. Calculul razei maxime se face folosind relația (5), razei minime și razei medii pe baza relațiilor (6) și (7).

Se consideră imaginea contur în care s-a fixat centrul de greutate (cu bold) (Fig. 3).

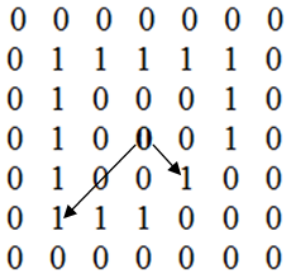


Fig. 3. Centrul de greutate, raza minimă și raza maximă.

Raza minimă este marcată prin săgeata mai mică, iar raza maximă este marcată prin săgeata mai mare în Fig. 3. Calculând distanțele euclidiene de la centrul de greutate la punctele de pe contur, fără a ține seama de lungimea elementară Δ, se obțin următoarele rezultate:

$$R_{\min} = \sqrt{2}, \qquad R_{Max} = 2\sqrt{2}, \qquad R_{med} = \frac{1}{14}\left(7\sqrt{2} + 8 + 6\sqrt{5}\right)$$

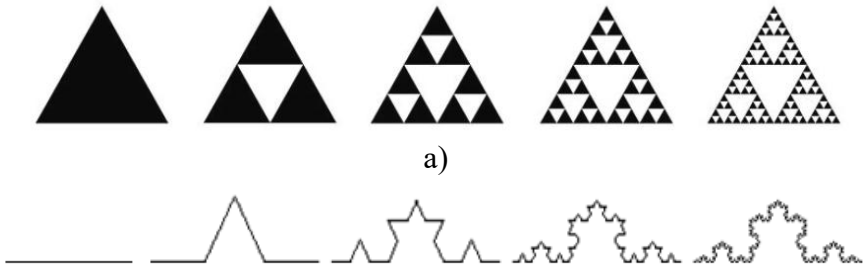
Extragerea trăsăturilor fractale

În natură, pot exista forme complexe care nu pot fi evaluate nici în cadrul geometriei clasice, nici în cadrul topologiei. Aceste forme își modifică proprietățile geometrice în funcție de scara de reprezentare (de exemplu, lungimea unei linii de coastă devine din ce în ce mai mare, dacă scara de reprezentare se mărește și apar noi detalii) sau au proprietăți de autosimilaritate. Pentru a modela și evalua mai precis structuri fizice complexe, având margini neregulate, precum frunzele, țărmurile, galaxiile etc., a fost necesară considerarea unei noi geometrii, numită geometrie fractală. Astfel, putem spune că geometria fractală este o extindere a geometriei clasice. În prelucrarea imaginilor vom considera fractalii ca fiind submulțimi ale planului R^2 de forma unor obiecte neregulate cu detalii infinite la orice scară de reprezentare. Mandelbrot a arătat că liniile de coastă și liniile de graniță sunt fractali. Tot el a definit, ulterior, fractalii ca fiind obiecte alcătuite din copii ale lor la scară mai mică (prezintă un grad de autosimilaritate).

Pentru a caracteriza obiectele fractale s-a introdus noțiunea de **dimensiune fractală** care este foarte importantă în evaluarea cantitativă a obiectelor fractale, deoarece ea permite evaluarea gradului de neregularitate al unui contur, linie de margine sau suprafață. Un fractal este o formă a cărei dimensiune fractală este strict mai mare decât dimensiunea sa topologică, nefiind un număr întreg.

Dimensiunea fractală crește odată cu gradul de neregularitate al conturului. Definirea dimensiunii fractale a făcut obiectul multor încercări, chiar ale acelorași autori. Unele abordări au folosit noțiunea de *autosimilaritate*. Alte abordări au folosit noțiunea de *acoperire în sens minimal*. Dată fiind o mulțime din plan A, se spune că A este autosimilară dacă A este reuniunea a *n* copii distincte ale sale, fiecare fiind redusă la o scară de 1/*s*. Fractalii artificiali (generați pe calculator) prezintă, în general, proprietatea de autosimilaritate. În Fig. 4 sunt date două exemple de fractali artificiali:

a) Triunghiul lui Sierpinski construit prin partiționarea unui triunghi echilateral de latură l în patru triunghiuri echilaterale de latură l/2, apoi acestea, în triunghiuri echilaterale de latură l/4 ș.a.m.d.– Fig. 4.a;
b) Curba lui Koch, obținută pornind de la un segment de dreaptă de lungime *d* – Fig. 4.b. Segmentul se împarte în trei segmente de lungime *d*/3 și se înlocuiește segmentul din mijloc cu două segmente de lungime *d*/3 care ar forma cu segmentul lipsă un triunghi echilateral. Procedeul continuă pentru fiecare dintre cele patru segmente obținute ș.a.m.d.



a)

b)

Fig. 4. Fractali artificiali: a) triunghiul lui Sierpinski, b) curba lui Koch.

Pentru obiecte având proprietatea de autosimilaritate, se definește dimensiunea fractală în felul următor. Se notează cu *N* numărul de copii obținut prin scalarea cu factorul *r* (*r*<*1*). Între *N* și *r* se stabilește următoarea relație (8):

$$Nr^{D_f} = 1 \tag{8}$$

Logaritmând relația de mai sus, se obține dimensiunea fractală (9) pentru obiecte autosimilare:

$$D_f = -\frac{\ln N}{\ln r} \tag{9}$$

Pentru obiectele naturale, se adoptă o altă definiție a dimensiunii fractale. Se menționează că, în cazul obiectelor fractale autosimilare, se obțin aceleași valori ale dimensiunilor fractale prin ambele definiții. Fie, în acest sens, A o mulțime compactă din plan și *N(A,r)* cel mai mic număr de discuri de rază *r* necesare pentru a acoperi mulțimea *A*. Dacă limita următoare (10) există, atunci această limită se numește *dimensiunea fractală* a lui *A*.

$$D_f(A) = \lim_{r \to 0} \frac{\ln(N(A,r))}{\ln(1/r)} \tag{10}$$

Deoarece calculul direct al dimensiunii fractale este imposibil de efectuat practic, în prezent există mai multe modalități de a evalua dimensiunea fractală, dintre care cea mai folosită este algoritmul box-counting. Astfel, o primă modalitate de a evalua dimensiunea fractală este de a acoperi mulțimea *A* cu domenii delimitate de laturile pătratelor obținute prin împărțirea

succesivă la 2 a laturii unui pătrat inițial, considerat pe direcțiile axelor de coordonate, ce conține această mulțime. În acest caz, se poate considera drept definiție, următoarea limită (11), dacă ea există:

$$D_F(A) = \lim_{n\to\infty} \frac{\ln\left(N(A,n)\right)}{\ln\left(2^n\right)} \tag{11}$$

unde n este numărul de ordine al diviziunii ($L/2^n$) fiind latura pătratului de acoperire și L, latura pătratului inițial, iar $N(A,n)$ este numărul de pătrate corespunzătoare acestei diviziuni, care au intersecție nevidă cu mulțimea A. Pentru evaluarea pantei caracteristicii logaritmice, având în vedere faptul că această caracteristică nu este în mod necesar liniară, se pot folosi mai multe estimații, în funcție de aspectul caracteristicii obținute.

O primă estimație o constituie *panta aproximativă a curbei logaritmice* (*curba log-log*), descrisă prin punctele de coordonate $(\ln(1/r), \ln N(r)) = (x,y)$, determinată prin regresie liniară (12 și 13):

$$y = a\,x + b, \tag{12}$$

unde:

$$a = D_f = \frac{n\sum_{i=1}^{n} x_i y_i - \left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} y_i\right)}{n\sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i\right)^2} \tag{13}$$

este dimensiunea fractală estimată, iar n reprezintă numărul de puncte din caracteristica logaritmică.

Dacă există mai multe puncte coliniare, o altă estimație a dimensiunii fractale poate fi considerată panta dreptei care unește cele mai multe puncte.

Unind două câte două punctele succesive din caracteristica log-log și considerând pantele dreptelor determinate de fiecare pereche de puncte, se poate trasa histograma pantelor (frecvența de apariție în funcție de valoarea pantei). În acest caz, dimensiunea fractală poate fi estimată prin valoarea pantei de frecvență maximă. În cazul în care histograma este multimodală se poate considera că în imagine se află un *multifractal* (obiectul conține porțiuni diferite ca structură, cu dimensiuni fractale diferite).

Pentru categoria obiectelor fractale autosimilare (care sunt, de obicei, fractali artificiali) există o expresie mai simplă (14) a dimensiunii fractale D_f:

$$D_f = \frac{\ln N_c}{\ln\left(1/s\right)} \tag{14}$$

unde N_c reprezintă numărul de copii, iar $1/s$ reprezintă scara de reprezentare.

Astfel, în cazul triunghiului lui Sierpinski (Fig. 1.a), alcătuit din 3 copii ale sale, la scara 1/2, se obține $D_f = \ln3/\ln2 = 1{,}5849$, iar pentru linia de coastă Koch (Fig. 1.b), formată din 4 copii ale sale, la scara 1/3, se obține $D_f = \ln4/\ln3 = 1{,}2618$.

Uneori, alegerea pragului de binarizare poate să influențeze evaluarea dimensiunii fractale a obiectului considerat. Pentru a atenua această influență, se poate folosi următorul algoritm, bazat tot pe dimensiunea box-counting, dar care utilizează toate nuanțele de gri (sau de culoare) de interes din zona selectată.

Algoritmi pentru evaluarea dimensiunii fractale

a) Algoritmi pentru calculul dimensiunii fractale din imagini binarizate

În practică, datorită rezoluției limitate a reprezentării numerice a imaginilor, calculul dimensiunii fractale aplicând direct definiția este imposibil. Pentru calculul dimensiunii fractale se poate folosi *algoritmul box-counting*, pornind de la definiția (11) și ținând seama de restricțiile de rezoluție. Acest algoritm, aplicabil imaginilor binarizate, constă în următoarele etape:

a) Se citește imaginea binară originală.
b) Se notează $k = 1/r$ și se inițializează $k = 2$ și $N(k) = 0$.
c) Se calculează dimensiunea box-counting în felul următor:
   i) se împarte imaginea în patru pătrate echivalente și se marchează cele care conțin puncte ale obiectului;
   ii) se numără pătratele marcate, $N(k)$;
   iii) se face $k = 2k$ și procedeul continuă de la punctul i), împărțind fiecare pătrat obținut la pasul precedent în patru pătrate echivalente și se marchează cele care conțin puncte ale conturului;
   iv) procedeul continuă cât timp permite rezoluția imaginii*;*
   v) valorile obținute, $k = 2, 4, 8, \ldots$ și $N(k)$ sunt logaritmate și reprezentate grafic într-o curbă, având coordonatele $(x,y) = (\ln(k), \ln(N(k)))$;
   vi) se calculează panta aproximativă a curbei log-log (de regresie liniară) (11), (13) sau panta dreptei care unește cele mai multe puncte ale curbei (variantă); valoarea pantei reprezintă dimensiunea box-counting $D_{bc} \approx D_f$.

Exemplu:

Pentru obiectul din Fig. 5, să se aplice algoritmul box-counting considerând 4 puncte ale caracteristicii (x,y), în afară de origine.

- Pentru $k = 2$, rezultă 4 pătrate, $N = 3$ și $(x_1,y_1) = (0{,}693; 1{,}099)$.
- Pentru $k = 4$, rezultă 16 pătrate, dintre care au intersecție nevidă cu figura analizată un număr $N = 9$. Rezultă: $(x_2,y_2) = (1{,}386; 2{,}197)$.
- Pentru $k = 8$, rezultă 64 de pătrate, dintre care au intersecție nevidă cu figura analizată un număr $N = 19$. Rezultă: $(x_3,y_3) = (2{,}079; 2{,}944)$.
- Pentru $k = 16$, rezultă 256 pătrate, dintre care au intersecție nevidă cu figura analizată un număr $N = 54$. Rezultă: $(x_4,y_4) = (2{,}772; 3{,}989)$.

Aplicând metoda regresiei liniare pentru punctele obținute, dimensiunea fractală a obiectului din Fig. 5 poate fi aproximată prin: $D_f = 1{,}359$.

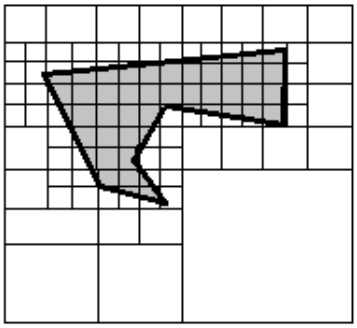


Fig. 5. Exemplificarea algoritmului box-counting.

b) Metode pentru calculul dimensiunii fractale din imagini cu nuanțe de gri

Pentru calculul dimensiunii fractale din imagini cu mai multe nuanțe de gri se pot utiliza mai multe metode: a) medierea dimensiunilor fractale obținute prin metoda box-counting, descrisă mai sus, pentru diferite praguri de binarizare ale imaginii; b) metoda box-counting diferențială, etc.

Lacunaritatea

Proprietatea de lacunaritate a fost introdusă în analiza fractală a imaginilor pentru a îmbunătăți descrierea interiorului obiectelor fractale. În mod intuitiv, dacă structura unui fractal prezintă lacune sau găuri, atunci se consideră că prezintă lacunaritate mare. Cu alte cuvinte, o valoare mare a lacunarității înseamnă că pixelii sunt grupați, generând o varietate mare de insule sau goluri. De asemenea, evaluarea lacunarității este un instrument valoros în analiza texturilor; o valoare mare a lacunarității indică un puternic caracter eterogen al texturii.

Calculul valorilor lacunarității se bazează pe distribuția și grupările pixelilor din imagine. Metoda clasică constă în acoperirea cu pătrate de latură fixă l a imaginii de analizat. Acoperirea se poate face în două moduri: cu pătrate adiacente (nesuprapuse) sau cu pătrate suprapuse parțial (cunoscută sub denumirea de sliding-box). Pentru fiecare dimensiune a pătratelor de acoperire se calculează lacunaritatea respectivă. În unele cazuri se efectuează și o medie a lacunarității.

În cazul imaginilor binare, lacunaritatea λ este calculată ca raport între deviația standard σ și media μ, caracteristice fiecărui pătrat de latură l și poziționare g conform relației (15):

$$\lambda_{l,g} = \left(\frac{\sigma_{l,g}}{\mu_{l,g}} \right)^2 \tag{15}$$

Extragerea trăsăturilor de textură

De multe ori, în analiza imaginilor, se întâlnesc cazuri care prezintă regiuni cu variații locale de intensitate, conducând la apariția unor particularități, elemente sau forme repetate, numite *texturi*. Formele pot fi rezultatul unor proprietăți mecanice ale suprafeței (exemple: denivelări sau șanțuri orientate) sau ele pot fi rezultatul unor proprietăți optice (exemple: diferențe de intensitate sau de culoare pe o suprafață). Astfel, în linii mari, textura poate fi definită ca o structură compusă din multe elemente (forme) similare, ordonate, astfel încât niciunul să nu iasă în evidență, observatorul având o impresie globală unitară (Fig. 6).



Fig. 6. Obiect sintetic având cinci texturi diferite.

Deoarece este greu să se dea o definiție riguroasă a texturii, în literatura de specialitate există mai multe încercări de a defini o textură. Astfel, dacă elementele care alcătuiesc textura (numite *textoni*) sunt identice și strict ordonate (de exemplu, o tablă de șah), atunci *textura* se numește *deterministă*. Dacă elementele nu sunt identice, dar sunt asemănătoare, iar dispunerea lor se face după anumite legi statistice, atunci *textura* se numește *aleatoare*. Intermediar între modelul determinist și modelul aleator există modelul de *textură observabilă*.

Din alt punct de vedere, se întâlnesc *texturi uniforme*, care conțin un mare număr de pete uniforme de dimensiuni mici (numite primitive), aranjate potrivit unei reguli de amplasare, iar formele petelor și pozițiile lor sunt guvernate de variabile aleatoare. Pentru caracterizarea (descrierea) lor, se folosesc, de regulă, caracteristici statistice.

Pentru a aprecia faptul că într-o imagine există textură, trebuie să fie evaluate intuitiv o serie de proprietăți. Cele mai importante proprietăți ale texturilor sunt următoarele:

- Textura este o proprietate de domeniu (nu se definește textura într-un punct). Existența texturii presupune modificări ale valorilor de gri sau de culoare din ferestre de dimensiuni mici ale imaginii. Dimensiunea acestor ferestre depinde de tipul texturii sau de mărimea primitivelor ce definesc textura.
- Textura implică o distribuție spațială a nivelului de gri.
- Textura unei imagini poate fi observată și analizată doar la diverse rezoluții ale imaginii.
- O regiune din imagine este percepută ca având textură atunci când numărul de obiecte elementare (primitive) adiacente și grupate în regiune este foarte mare.

Pe de altă parte, următoarele proprietăți observabile joacă un rol important în descrierea unei texturi: uniformitatea, densitatea, granulația, asprimea, liniaritatea, direcţionalitatea, frecvența și faza. Unele dintre aceste proprietăți nu sunt independente.

Metodele de analiză a texturii pot fi divizate în două categorii: metode statistice și metode structurale. Abordarea statistică tratează texturile ca fenomene statistice și lucrează bine cu microtexturi fără construcții clare. În acest caz, textura este descrisă prin proprietățile statistice ale intensităților și pozițiilor pixelilor. Cele mai folosite metode de abordare statistică sunt histogramele de diferență pentru nivelul de gri și indicatorii statistici obținuți prin intermediul matricelor de coocurență. A doua categorie, abordarea structurală, folosește primitivele de textură, numite texeli sau textoni, și lucrează bine cu macrostructuri având construcții clare. În scopul descrierii unei structuri complexe cu ajutorul primitivelor, se formează un vocabular ce conține aceste primitive și se utilizează relații (reguli de formare) între ele pentru a forma șiruri și grafuri.

Un caz aparte de analiză a texturilor îl constituie utilizarea metodelor și tehnicilor fractale descrise anterior. De multe ori, pentru o analiză mai exactă se folosesc tehnici combinate.

Utilizarea trăsăturilor statistice pentru clasificarea și descrierea texturilor este una dintre primele metode propuse în literatura de specialitate.

Histograma nivelului de gri [h] pentru imaginea [G] arată frecvența de apariție $h(x)$ a fiecărui nivel de gri x. Dacă imaginea este cuantizată pe K niveluri de gri (x_1 , x_2 , ..., x_K), atunci [h] este un vector având K elemente. Pentru evidențierea proprietăților statistice ale texturii, se folosesc următoarele caracteristici, calculate din [h] și care furnizează informații generale despre nivelul de gri, excluzând informațiile spațiale:

- *Nivelul de gri mediu* (16), μ:

$$\mu = \frac{1}{N}\sum_{i=1}^{K} x_i h(x_i) \tag{16}$$

unde:

$$N = \sum_{i=1}^{K} h(x_i) \tag{17}$$

este numărul de puncte din [G]. Nivelul mediu μ este o măsură globală a luminozității scenei.

- *Nivelul de gri median* este nivelul de gri pentru care jumătate din punctele imaginii sunt mai întunecate și jumătate sunt mai luminoase.

- *Dispersia nivelului de gri* (18)*,* σ^2, se definește prin relația:

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{K} (x_i - \mu)^2 h(x_i) \tag{18}$$

Dispersia este o măsură globală a contrastului din [*G*]. Dacă dispersia are o valoare mică, atunci nivelul de gri este apropiat de nivelul mediu.

Caracteristicile statistice prezentate mai sus se numesc *caracteristici statistice de ordinul întâi.* Ele sunt limitate în descrierea imaginii [*G*]*,* deoarece nu țin cont de modul de amplasare a punctelor de un anumit nivel de gri. De exemplu, [*h*] este același și în cazul în care jumătatea stângă a imaginii este neagră, iar jumătatea dreaptă este albă, și în cazul zgomotului de tip *sare și piper*. Pentru descrierea statistică mai precisă a imaginii, se folosesc caracteristici statistice de ordinul al doilea care țin seama și de poziția relativă a pixelilor. Un exemplu de caracteristică statistică de ordinul doi, utilizată în clasificarea texturilor, este *funcţia de autocorelaţie normalizată*.

Un alt mod de a obține informații despre repartiția spațială a nivelurilor de gri din [*G*] este acela de a calcula caracteristicile statistice pentru deplasări mici ale imaginii (*caracteristici statistice locale*). Pentru a arăta cum proprietățile locale influențează descrierea texturii, să considerăm o deplasare d = (x, y) și funcția nivel de gri diferență (19):

$$G_d(x,y) = G(x,y) - G(x+\Delta x, y+\Delta y) \tag{19}$$

Presupunând că imaginea este compusă din pete (elemente primitive) de diametru Δ, dacă $\Delta x<\Delta$ și $\Delta y<\Delta$, histograma diferenței η_d (corespunzătoare lui G_d) va conține valorile mari concentrate lângă origine. Dacă *d* este mare, atunci η_d va avea valorile împrăștiate.

Pentru deplasarea *d* pot fi definite diferite caracteristici statistice locale, cum ar fi:

- *valoarea medie* (20):

$$\frac{1}{N}\sum_{i=1}^{K} x_i p_d(x_i) \tag{20}$$

- *valoarea medie pătratică* (21):

$$\sum_{i=1}^{K} x_i^{\,2} p_d(x_i) \tag{21}$$

unde $p_d(x_i) = \eta_d(x_i)$ este densitatea de probabilitate a nivelului de gri diferență, G_d.

Matricea de coocurenţă

Matricele de coocurenţă au devenit unele dintre cele mai cunoscute și mai larg utilizate mijloace pentru extragerea unor trăsături de textură eficiente, de tipul caracteristicilor statistice de ordinul doi. Matricele de coocurenţă pentru o imagine având *K* niveluri de gri au dimensiunea $K\times K$ și depind de vectorul de deplasare $d = (\Delta x, \Delta y)$, unde Δx este deplasarea în număr de linii, iar este Δy deplasarea în număr de coloane. Elementul (i,j) al unei matrice de coocurenţă P_d, asociată deplasării *d*, este numărul de apariții, în imagine, ale perechilor de pixeli având nivelurile de gri *i* și, respectiv, *j*, considerate astfel încât pixelul de nivel *i* este situat în poziția (x,y), iar pixelul de nivel *j* este situat în poziția $(x + \Delta x, y + \Delta y)$ (22):

$$(x,y),(t,v)\in N\times N,(t,v)=(x+\Delta x,y+\Delta y)\} \tag{22}$$

Sensurile pozitive ale deplasărilor Δx şi Δy se consideră ca în Fig. 7.



Fig. 7. Sensurile pozitive ale deplasărilor.

Matricele de coocurență evidențiază anumite proprietăți referitoare la distribuția spațială locală a nivelurilor de gri. De exemplu, dacă elementele nenule ale matricei *C* sunt concentrate în jurul diagonalei, atunci textura se consideră grosieră relativ la deplasarea *d*.

Matricele de coocurenţă astfel definite nu sunt simetrice. Pentru a obține matrice simetrică, se consideră suma (23):

$$[P_{ds}]=[P_d]+[P_{-d}] \tag{23}$$

Exemplu:

Se consideră imaginea din Fig. 8.

$$[G]=\begin{matrix}0&0&1&1&2&2&3&3\\3&3&0&0&1&1&2&2\\2&2&3&3&0&0&1&1\\1&1&2&2&3&3&0&0\\0&0&1&1&2&2&3&3\\3&3&0&0&1&1&2&2\end{matrix}$$

Fig. 8. Imagine exemplu.

Pentru imaginea din Fig. 8 se calculează matricele de coocurenţă $[P_{(1,0)}]$, $[P_{(-1,0)}]$, $[P_{(1,1)}]$, $[P_{(-1,1)}]$, $[P_{s(1,0)}]$, $[P_{s(1,1)}]$ obținându-se următoarele rezultate (Fig. 9):

$$[P_{(1,0)}]=\begin{matrix}0&0&0&10\\10&0&0&0\\0&10&0&0\\0&0&10&0\end{matrix}\qquad [P_{(-1,0)}]=\begin{matrix}0&10&0&0\\0&0&10&0\\0&0&0&10\\10&0&10&0\end{matrix}$$

$$[P_{(1,1)}]=\begin{matrix}4&0&0&5\\5&4&0&0\\0&5&4&0\\0&0&5&3\end{matrix}\qquad [P_{(-1,-1)}]=\begin{matrix}4&5&0&0\\0&4&5&0\\0&0&4&5\\5&0&0&3\end{matrix}$$

$$[P_{s(1,0)}]=[P_{(1,0)}]+[P_{(-1,0)}]=\begin{matrix}0&10&0&10\\10&0&10&0\\0&10&0&10\\10&0&10&0\end{matrix}$$

$$[P_{s(1,1)}]=[P_{(1,1)}]+[P_{(-1,-1)}]=\begin{matrix}8&5&0&5\\5&8&5&0\\0&5&8&5\\5&0&5&6\end{matrix}$$

Fig. 9. Matrice de coocurenţă simetrice P_s.

Din matricele de coocurenţă se pot extrage o serie de caracteristici statistice (24) – (27) utilizate ca trăsături în procesul de clasificare a texturilor. Acestea sunt definite în continuare și depind de deplasarea *d.*

Energia: este o măsură pentru distribuția nivelurilor de gri, valoarea sa fiind maximă fie atunci când acestea sunt constante, fie atunci când se repetă periodic. La fel ca în cazul matricei de coocurență a nivelurilor de gri de ordinul doi, și în cazul matricei de coocurență a nivelurilor de gri de ordinul n, energia — fiind opusul entropiei — exprimă gradul de ordine, de uniformitate a texturii.

$$\sum_{i=0}^{n_1-1}\sum_{j=0}^{n_2-1}P_d^2(i,j) \tag{24}$$

Entropia: este o măsură a incertitudinii a cantității de informație, având cea mai mare valoare atunci când elementele sunt toate egale.

$$-\sum_{i=0}^{n_1-1}\sum_{j=0}^{n_2-1}P_d(i,j)\log P_d(i,j) \tag{25}$$

Contrastul: descrie modul de variație al nivelurilor de intensitate ale texturii dintre pixelul de referință și vecinul său. Analizând structura matricei de coocurență a nivelurilor de gri, se pot obține informații cu privire la contrast: valori mari apropiate de diagonala principală și valori mici spre margini indică contrast scăzut, pe când valori mici apropiate de diagonala principală și valori mari spre margini indică contrast ridicat.

$$\sum_{i=0}^{n_1-1}\sum_{j=0}^{n_2-1}(i-j)^2 P_d(i,j) \tag{26}$$

Omogenitatea: arată gradul de similaritate în cadrul unei perechi de pixeli, valoarea sa fiind cu atât mai mare cu cât nivelurile de gri ale perechilor de pixeli sunt mai apropiate.

$$\sum_{i=0}^{n_1-1}\sum_{j=0}^{n_2-1}\frac{P_d(i,j)}{i+|i-j|} \tag{27}$$

Trăsăturile extrase din matricele de coocurență au o serie de dezavantaje, dintre care menționăm:

- nu există o metodă de selectare a deplasărilor *d* pentru care este necesar calculul acestor trăsături;
- nu există o metodă riguroasă de selectare a trăsăturilor statistice utilizate în procesul de clasificare;
- matricele de coocurenţă nu pot fi calculate pentru orice distanță *d* (de ex. pentru o distanță mai mare decât dimensiunea totală a imaginii).

Forme locale binare (LBP)

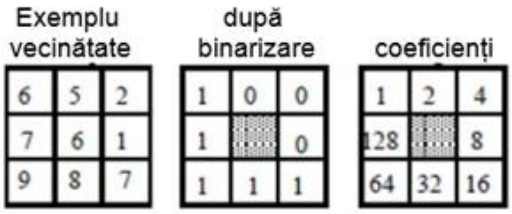
Metoda bazată pe forme locale binare (Local Binary Pattern - LBP) pentru analiza texturilor a fost introdusă la mijlocul anilor ’90.

Descriptorii bazați pe LBP sunt folosiți în multe aplicații moderne de învățare automată, de exemplu, în medicină, pentru detecția țesuturilor bolnave sau în aplicații de recunoaștere facială.

LBP a devenit unul dintre cei mai folosiți descriptori de textură datorită: a) invarianței la condițiile de iluminare, b) simplității computaționale (ceea ce permite respectarea cerințelor de timp real) și c) capacității de a codifica detalii fine.

LBP este un operator simplu, dar eficient, care atribuie fiecărui pixel al imaginii o valoare codificată binar, prin analiza proprietăților pixelilor dintr-o vecinătate a sa. Operatorul poate fi văzut astfel ca o abordare ce combină două metode tradiționale diferite, și anume metoda statistică și cea structurală.

Prima variantă a algoritmului, propusă de Ojala și colaboratorii, utilizează vecinătăți de 3×3 pixeli din imaginea cu niveluri de gri. Valorile pixelilor din această vecinătate sunt binarizate în funcție de valoarea pixelului central (dacă valoarea pixelului central este mai mare sau egală cu valoarea vecinului, este „1”; în caz contrar, este „0”), apoi sunt înmulțite cu puteri ale lui 2 în funcție de poziția în vecinătate și adunate pentru a obține o valoare atribuită pixelului central. Întrucât vecinătatea este formată din 8 pixeli, în total pot să apară $2^8 = 256$ valori diferite în funcție de valoarea relativă a pixelilor de pe margine față de cel central. O exemplificare poate fi observată în Fig. 10.



Pattern = 10001111

LBP = 1+16+32+64+128 = 241

Fig. 10. Exemplu de calcul aplicând algoritmul LBP original.

Prin înlocuirea pixelilor centrali ai vecinătăților cu valorile LBP se obține o nouă imagine pe care o numim imagine LBP. Făcând histograma valorilor din imaginea LBP, se obține histograma LBP (de multe ori se folosesc metode de grupare). Histograma LBP se poate reprezenta sub forma unui vector care poate fi folosit în procesul de clasificare a texturilor. În Fig. 11 este dat un exemplu de aplicare a operatorului LBP cu mențiunea că histograma LBP nu folosește elemente de grupare.

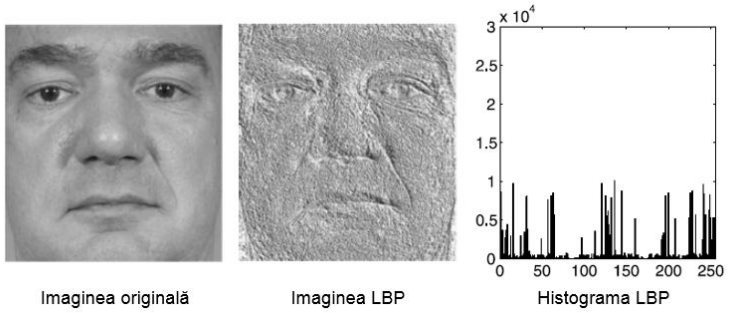


Fig. 11. Rezultatul obținut în urma aplicării operatorului LBP și construcția histogramei.

Histograma gradienților orientați (HOG)

Histograma gradienților orientați (HOG) este un descriptor local, bazat pe distribuția magnitudinii și orientării liniilor de contrast (muchiilor), utilizat în scopul identificării obiectelor din scenă. Acest descriptor se calculează prin împărțirea imaginii în celule și calcularea, pentru fiecare celulă, a histogramei orientării muchiilor (sau a direcției gradienților), analizând pixelii din celulă.

Gradientul este calculat la nivel de pixel și prin combinarea componentelor orizontale și verticale se pot extrage magnitudinea gradientului și orientarea gradientului. Amplitudinea gradientului indică tranzițiile în intensitate între pixeli. Pe de altă parte, orientarea gradientului reprezintă valorile unghiului la care tranzițiile în intensitate între pixeli avansează de-a lungul imaginii analizate.

Metoda propusă pentru calculul gradientului unei imagini *img* se bazează pe o operație de convoluție a imaginii trecute prin filtrul Sobel în scopul accentuării liniilor de contrast (se obține o estimare a gradientului). După determinarea componentelor G_x și G_y ale gradientului, mărimea

gradientului G_{mag} și orientarea gradientului G_{dir} pot fi calculate ca în relațiile de convoluție (28) - (31).

$$G_x = \begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix} * img \tag{28}$$

$$G_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} * img \tag{29}$$

$$G_{mag} = \sqrt{G_x{}^2 + G_y{}^2} \tag{30}$$

$$G_{dir} = \tan^{-1}\left(\frac{G_y}{G_x}\right) \tag{31}$$

Considerând mărimea și orientarea gradienților calculați în toți pixelii imaginii, următorul pas în algoritmul HOG este calculul histogramei prin metode de grupare. Se obține astfel un vector de valori (valorile histogramei) care este descriptorul numeric HOG utilizat în clasificarea texturilor (32). Deci, metoda de calcul al descriptorului HOG constă în implementarea unui vector histogramă H_{HOG} ce caracterizează tranzițiile locale în intensitate între pixeli și orientările acestor tranziții în imaginea analizată. În particular, H_{HOG} se poate defini ca un vector cu 9 componente reprezentând suma mărimilor gradienților pe 9 zone repartizate uniform în intervalul 0º-180º.

$$H_{HOG} = [b_1, b_2, ..., b_9]^T \tag{32}$$

În relația (32) fiecare element b_k, k = 1, ..., 9 reprezintă suma mărimilor gradienților având orientările încadrate în zonele corespunzătoare din intervalul 0º-180º. Un exemplu de histogramă HOG pentru leziuni de piele este prezentat în Fig. 12.

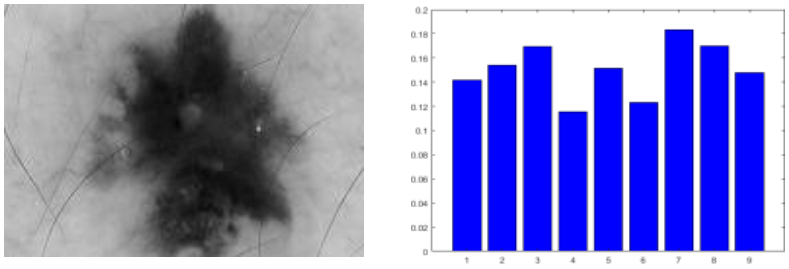
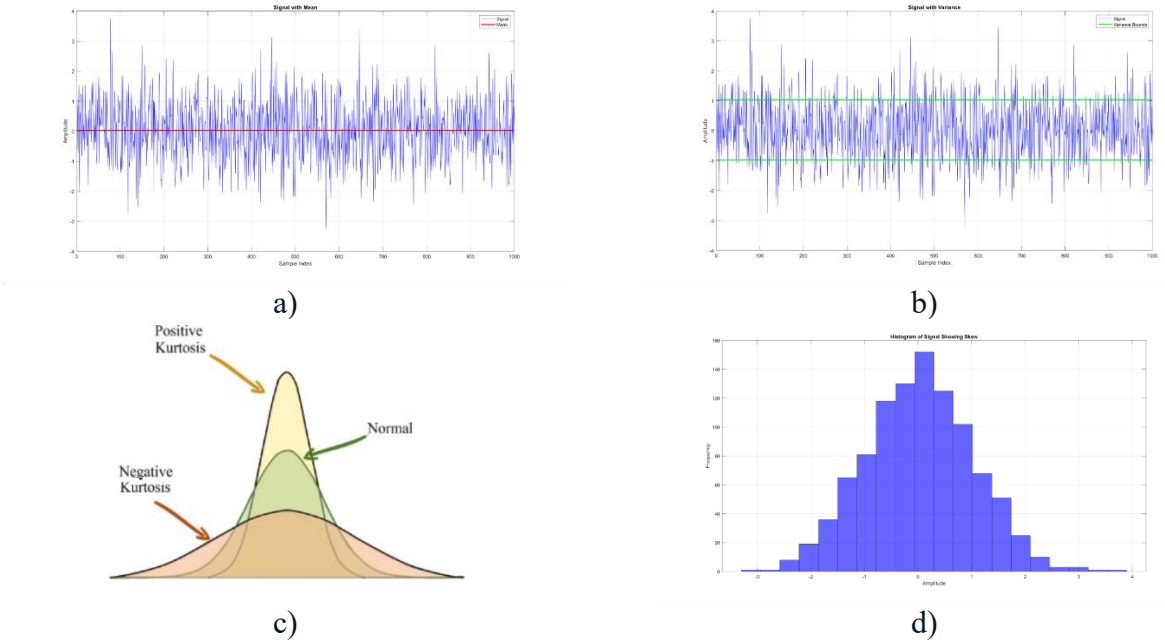


Fig. 12. Rezultatul obținut în urma aplicării operatorului HOG (construcția histogramei).

Cazul particular 2. Extragerea trăsăturilor din serii de timp

Calcularea diferitelor caracteristici statistice în domeniul temporal oferă perspective valoroase asupra comportamentului unei serii de timp. Media este un indicator al tendinței centrale a datelor. varianța măsoară răspândirea sau dispersia punctelor de date în jurul mediei. kurtosis (curtoză) și skewness (asimetria) sunt folosite pentru a descrie calitativ forma unui semnal (Fig. 13). În contextul analizei, acești parametri sunt utilizați pentru a cuantifica vârfurile sau aplatizarea unei distribuții, precum și gradul de simetrie în jurul valorii sale medii.



a) b) c) d)

Fig. 13. Caracteristici statistice în domeniul temporal: a) media, b) varianța, c) curtoza și d) asimetria.

Autocorelația și corelația încrucișată

Autocorelația măsoară asemănarea (similaritatea) dintre o serie de timp și o versiune întârziată a ei înșiși. Ajută la identificarea tiparelor repetate sau a comportamentului ciclic în cadrul datelor. O autocorelație puternică la un anumit decalaj indică un model repetitiv cu acea periodicitate. De exemplu, în cazul analizei datelor privind infecțiile virale, autocorelația poate dezvălui un caracter sezonier asociat cu focarele de infecție.

Un exemplu de utilizare a autocorelației pentru a identifica periodicitatea semnalului se prezintă în Fig. 14. În acest caz s-a pornit de la un semnal foarte zgomotos, după care s-a aplicat un filtru trece-bandă pentru a reduce zgomotul și apoi s-a utilizat funcția de autocorelație pentru a evalua cât de bine se corelează semnalul cu el însuși la diferite decalaje de timp. Din graficul de autocorelație se poate observa că semnalul se repetă cu o perioadă de aproximativ 1000.

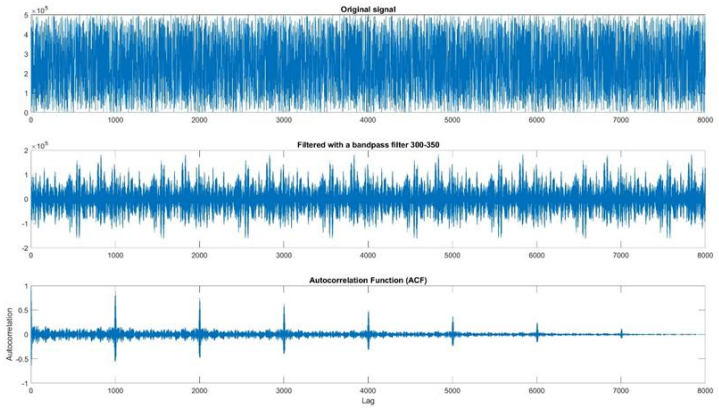


Fig. 14. Exemplu de utilizare a funcției de autocorelației pentru identificarea periodicității semnalului.

Corelația încrucișată explorează relația dintre două semnale diferite. Este util în găsirea de corelații și asocieri întârziate între două variabile. De exemplu, corelația încrucișată ar putea fi utilizată pentru a studia relația dintre temperatură și consumul de energie în timp. În fig. 15 se consideră două eșantioane, unul cu o anumită periodicitate și altul care are o periodicitate mai puternică. Folosind o corelație încrucișată, se dorește să se identifice dacă aceste două semnale se corelează între ele la diferite decalaje de timp. Din graficul de jos, se observă că există o corelație mai puternică la întârzieri negative și aproape nicio corelație la întârzieri pozitive.

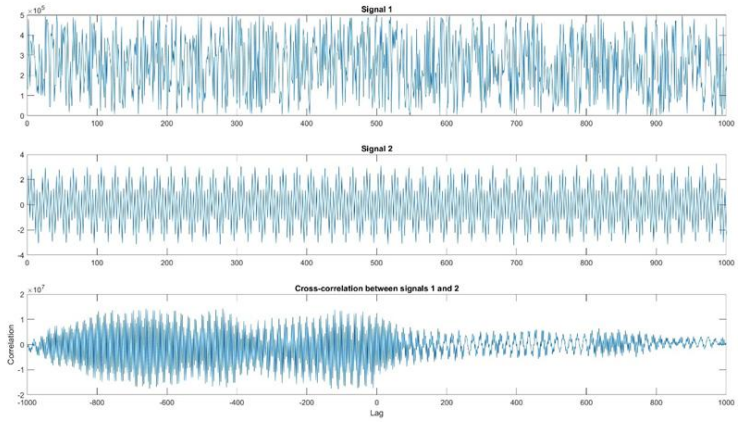
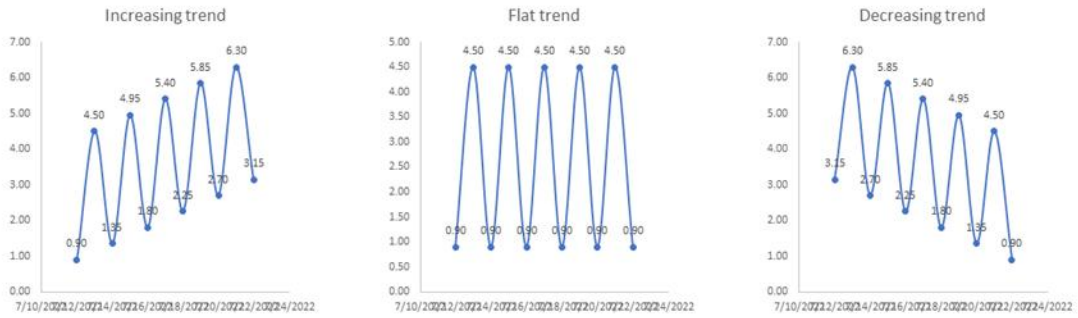


Fig. 15. Exemplu de corelație încrucișată.

Analiza tendințelor

Analiza tendințelor este utilă pentru înțelegerea comportamentului de bază pe termen lung al unui semnal. O tendință reprezintă direcția generală în care datele se deplasează pe o

perioadă extinsă. Tendințele pot fi crescătoare, descrescătoare sau plate (stabile), așa cum se observă în Fig. 16.



a) b) c)

Fig. 16. Exemple de trei tipuri de tendințe: a) tendință crescătoare, b) tendință plată sau stabilă și c) tendință descrescătoare.