Tehnici de învățare automată

Domeniul învățării automate este împărțit în subdomenii, în funcție de tipurile de probleme abordate. Există patru tehnici importante de învățare automată: supervizată, nesupervizată, semi-supervizată și prin recompensă.
Tehnicile de învățare automată sunt prezentate în Fig. 1, în care este descrisă pe scurt natura datelor de care au nevoie.

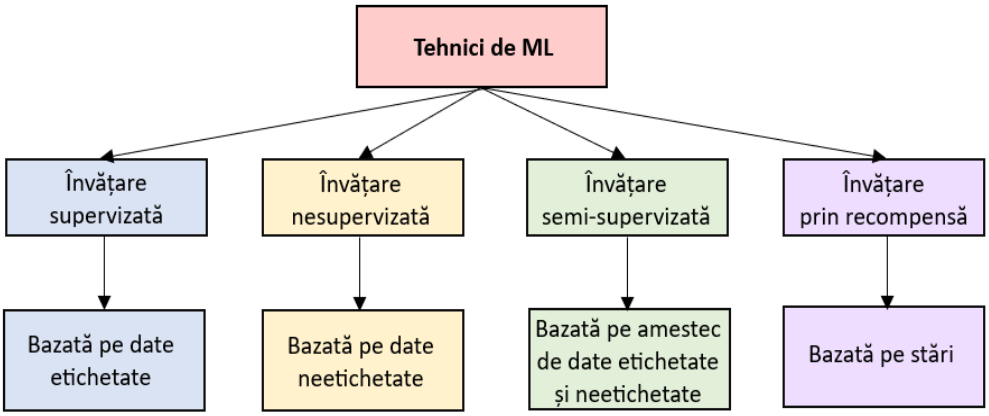


Fig. 1. Tehnicile de învățare automată și tipurile de date utilizate.

Învățarea supervizată

Învățarea supervizată este o abordare în care un algoritm este antrenat pe date de intrare etichetate pentru o anumită ieșire. Datele de intrare se numesc date de antrenament și au o etichetă sau un rezultat cunoscut, cum ar fi, de exemplu, benign/malign sau prețul unui produs la un moment dat. Mai precis, operatorul oferă algoritmului de învățare automată un set de date cunoscut care include intrările și ieșirile dorite, iar algoritmul trebuie să găsească o metodă pentru a determina cum să ajungă de la acele intrări la acele ieșiri. În timp ce operatorul știe răspunsurile corecte la problemă, algoritmul identifică modele în date, învață din observații și face predicții. Algoritmul face predicții și este corectat de către operator – iar acest proces continuă până când algoritmul atinge un nivel ridicat de precizie/performanță.

Cu cât modelul prezice mai multe rezultate corecte, cu atât este mai precis.

Altfel spus, în învățarea supervizată fiecare caz/exemplu de antrenare constă într-o pereche formată dintr-o intrare (X) și o ieșire/țintă (Y).

Există două tipuri de învățare supervizată: regresia și clasificarea.

• Regresia

În operația de regresie, programul de învățare automată trebuie să estimeze – și să înțeleagă – relațiile dintre variabile. Analiza de regresie se concentrează pe o variabilă dependentă și pe o serie de alte variabile în schimbare, ceea ce o face deosebit de utilă pentru predicție și prognoză. Mai precis, analiza de regresie ne ajută să înțelegem cum se modifică valoarea tipică a variabilei dependente (sau „variabila criteriu”) atunci când variază oricare dintre

variabilele independente. Ieșirea/ținta este un număr real sau un vector de numere reale. Exemple: analiza și predicția vremii (temperatura mâine la prânz), prognoza vânzărilor și a promoțiilor (prețul unui produs peste 12 luni), prognoza financiară.

• Clasificarea

Clasificarea este o metodă de învățare automată supervizată în care modelul încearcă să prezică eticheta corectă (clasa) a unei date de intrare. Cel mai simplu caz este o alegere 0 sau 1, dar putem avea, de asemenea, mai multe etichete posibile. Ieșirea țintă este o etichetă de clasă.

Clasificarea în cadrul învățării automate supervizate are aplicații diferite în mai multe domenii ale vieții noastre de zi cu zi. Mai departe sunt prezentate câteva exemple din diferite domenii:

Sănătate

Realizarea unui model de învățare automată care să aibă la bază date istorice ale pacienților poate ajuta specialiștii în domeniul sănătății cu sisteme de suport prin care să crească precizia diagnosticului:

- De exemplu, în timpul pandemiei de COVID-19, au fost implementate modele de învățare automată pentru a prezice eficient dacă o persoană a avut sau nu COVID-19.
- Cercetătorii pot folosi modele de învățare automată pentru a prezice noi boli care sunt mai probabile să apară în viitor.

Educație

Educația este unul dintre domeniile care se ocupă de cele mai multe date textuale, video și audio. Aceste informații nestructurate pot fi analizate cu ajutorul tehnologiilor de procesare a limbajului natural pentru a îndeplini diferite sarcini precum:

- Clasificarea documentelor pe categorii.
- Identificarea automată a limbajului de bază al documentelor în timpul aplicării și manipulării acestora.
- Analiza sentimentelor pe baza feedbackului studenților referitor la un profesor.

Transport

Transportul este o componentă cheie a dezvoltării economice a multor țări. În acest domeniu se folosesc modele de învățare automată și de deep learning:

- Pentru a prezice locația geografică care va avea o creștere a volumului de trafic.
- Previzionarea problemelor potențiale care pot apărea în anumite locații din cauza condițiilor meteorologice.

Agricultură durabilă

Agricultura este unul dintre cei mai valoroși piloni ai supraviețuirii umane. Introducerea durabilității poate ajuta la îmbunătățirea productivității fermelor la un alt nivel, fără a deteriora mediul:

- Prin utilizarea modelelor de clasificare pentru a prezice ce tip de teren este potrivit pentru un anumit tip de sămânță.
- Prezicerea vremii pentru a-i ajuta pe fermieri să ia măsurile preventive adecvate.

Un set de date neetichetate se poate transforma într-un set de date etichetate prin adnotare cu ajutorul unui operator uman/computer. Tabelul 1 prezintă cinci exemple de date neetichetate care pot fi etichetate pe baza diferitelor criterii. A doua coloană a tabelului denumită „Exemplu de judecată pentru etichetare" exprimă un criteriu posibil pentru fiecare exemplu de date, a treia coloană descrie posibilele etichete ca decizie, iar a patra coloană informează ce actor poate prelua rolul de supervizor. În primele patru exemple, sistemele pot fi aplicate în analiza sentimentelor, recunoașterea imaginilor și tehnologiile de detectare a vorbirii și pot avea ca supervizor posibil uman sau computer, în timp ce în ultimul caz de detectare a tumorilor, personalul obișnuit nu poate eticheta zonele cu potențiale probleme și sunt necesare servicii costisitoare ale experților pentru etichetare.

Tabelul 1. Exemple de date neetichetate împreună cu etichetele posibile

Exemple de date neetichetate	**Exemplu de judecată pentru etichetare**	**Etichete posibile**	**Supervizor posibil**
Tweeter	Analiza sentimentului	Pozitiv/ Negativ	Uman/ Computer
Imagine	Conține casă și mașină	Da/ Nu	Uman/ Computer
Înregistrare audio	Rostirea cuvântului fotbal	Da/ Nu	Uman/ Computer
Înregistrare video	Sunt folosite arme în videoclip?	Violent/ Non-violent	Uman/ Computer
Radiografie X-Ray	Prezența tumorii în radiografie	Prezent/ Absent	Expert/ Computer

Chiar dacă clasificarea și regresia sunt ambele din categoria învățării supervizate, ele nu sunt la fel.

- Sarcina de predicție este o *clasificare* atunci când variabila țintă este discretă. Un exemplu poate fi o aplicație pentru identificarea sentimentului de bază din analiza unei bucăți de text.
- Sarcina de predicție este o *regresie* atunci când variabila țintă este continuă. Un exemplu poate fi predicția salariului unei persoane având în vedere gradul de studii, experiența anterioară de muncă, locația geografică și nivelul de vechime.

Pașii de bază în timpul implementării învățării supervizate sunt următorii:

- Determinarea tipului de date care vor fi utilizate la învățarea supervizată.
- Colectarea și etichetarea datelor.
- Împărțirea setului de date în date de antrenare, validare și testare.
- Alegerea unui algoritm pentru modelul de învățare automată.
- Rularea algoritmului cu setul de date de antrenare și validare și evaluarea performanțelor de învățare.
- Testarea modelului.
- Evaluarea performanțelor finale.

Raportul optim la împărțirea înregistrărilor cu date suficiente între fiecare funcție – antrenare, validare și testare – depinde de utilizarea aplicației, tipul de model și dimensiunile datelor. Majoritatea modelelor ML au nevoie de un număr substanțial de scenarii pe care să se antreneze.

Modelele de învățare implică următoarele variabile:
• Input: X – vector de p componente (intrări, regresor, caracteristici, variabile independente)
• Output: Y – datele de ieșire (variabila dependentă, răspuns, țintă)
• Variabilă cantitativă (ex., vârsta, înălțimea, prețul, venitul, etc.) vs. variabilă calitativă (genul unei persoane, diagnostic de cancer etc.)
o În problemele de regresie Y este o variabilă cantitativă (ex.: prețul, tensiunea arterială, etc.);
o În problemele de clasificare Y ia valori într-o mulțime finită;

Antrenarea**:** fiind dată o mulțime de antrenare X împreună cu răspunsul dorit Y, $\{(X_1,Y_1),\ldots,(X_N,Y_N)\}$, se estimează predicția funcției f prin minimizarea erorii de predicție pe mulțimea de antrenare, unde $Y_i = f(X_i)$.
Acestea sunt observații (exemple, instanțe) ale unor măsurători.
În cazul învățării supervizate, pe baza datelor de antrenare, se dorește atingerea următoarelor obiective:
• Predicția corectă pe date de test noi (date care nu apar în datele de antrenare);
• Determinarea intrărilor care influențează ieșirile și înțelegerea modului în care se realizează această influență;
• Determinarea calității acestor predicții și inferențe

$$Y = f(X)$$

Y = ieșirea; f = funcția de predicție; X = trăsătura extrasă

Deci, pentru a asigura algoritmi fiabili și robuști, în procesul de antrenare sunt necesare următoarele trei componente: *cantitate* (date suficiente pentru ca modelul să învețe), *calitate* (este esențial să fie incluse date pe care este bazată aplicația), *diversitate* (necesită algoritmi antrenați de mai multe ori pe intrare pentru a simula majoritatea, dacă nu toate, cazurile probabile și posibile).

În etapa de validare, modelele cu puțini hiperparametri sau deloc sunt ușor de validat și reglat. Astfel, un set de date relativ mic în general este suficient. În schimb, modelele cu hiperparametri multipli necesită date suficiente pentru a valida intrările probabile. În general, repartizarea a 80% din date pentru antrenare, 10% pentru validare și 10% pentru a testa scenarii ar trebui să fie o împărțire inițială rezonabilă.

Testarea: se aplică funcția f pe un exemplu de test X (date care nu au fost folosite în procesul de antrenare) și se prezintă ieșirea ca fiind valoarea funcției $Y = f(X)$.

Etichetele prezise pot fi atât numere, cât și categorii. De exemplu, dacă estimăm prețurile caselor, atunci producția este un număr. În acest caz, modelul este un model de regresie. Dacă

anticipăm dacă un e-mail este spam sau nu, rezultatul este o categorie, iar modelul este un model de clasificare.

Exemple de învățare supervizată
Clasificarea imaginilor este o problemă specifică în domeniul vederii computerizate. Scopul este de a prezice clasa căreia aparține o imagine sau un obiect din imagine. În acest set de probleme, suntem interesați să găsim eticheta de clasă (numele clasei) a unei imagini (obiect sau formă).
O problemă care necesită luarea în considerare a multor parametri diferiți este predicția condițiilor meteorologice într-o anumită locație. Pentru a face previziuni corecte pentru vreme, trebuie luați în considerare diverși parametri, inclusiv date istorice de temperatură, precipitații, vânt, umiditate și așa mai departe. Această problemă poate necesita dezvoltarea unor modele complexe supervizate care includ sarcini multiple. Prezicerea temperaturii de astăzi este o problemă de regresie, în care etichetele de ieșire sunt variabile continue. În schimb, a prezice dacă va ninge sau nu mâine este o problemă de clasificare binară.
Un alt exemplu de învățare supervizată este problema de clasificare a textului. În acest set de probleme, scopul este de a prezice eticheta de clasă a unei anumite porțiuni de text. O altă aplicație utilizată în clasificarea textului este aceea de a prezice sentimentul indus de un fragment de text, cum ar fi pe Twitter sau o recenzie a unui produs. Acesta este utilizat pe scară largă în industria comerțului electronic pentru a ajuta companiile să determine comentariile negative făcute de clienți și să identifice care sunt clienții nemulțumiți și produsele respective.
În domeniul financiar și bancar pentru detectarea fraudei cu cardul de credit (fraudă, non-fraudă). Învățarea supervizată oferă unii dintre cei mai importanți algoritmi de detectare a anomaliilor. Detectarea spam-ului din e-mail (spam, non-spam).
În zona de marketing, o serie de algoritmi de extragere a textului este utilizată pentru analiza sentimentului indus de text (fericit, nefericit).
În medicină, pentru prezicerea riscului de boală (risc ridicat, risc scăzut) sau pentru prezicerea probabilității de insuficiență cardiacă congestivă.

În continuare, sunt prezentate o serie de **avantaje și dezavantaje** ale învățării automate supervizate.

Avantaje:
- **Permite mai multă specificitate** cu privire la definirea etichetelor. Cu alte cuvinte, se poate antrena algoritmul pentru a distinge diferite clase în care se poate stabili o limită de decizie ideală.
- **Se știe numărul de clase** care se dorește a fi avute.
- **Datele de intrare sunt foarte bine cunoscute** și sunt etichetate.
- **Mai puțin predispuse la supraadaptare**: pe măsură ce datele de antrenament sunt etichetate, modelele au mai puțină tendință de a se supraadapta la datele de antrenament.
- **Rezultatele obținute prin metoda supervizată sunt mai precise** și mai fiabile în comparație cu rezultatele produse de tehnicile nesupervizate de învățare automată. Acest lucru se datorează în principal faptului că datele de intrare în algoritmul supervizat sunt bine cunoscute și etichetate. **Aceasta este o diferență cheie între învățarea supervizată și nesupervizată.**
- **Gamă largă de algoritmi:** există mulți algoritmi maturi de învățare supervizată.

Dezavantaje:

- Învățarea supervizată **poate fi o metodă complexă** în comparație cu metoda nesupervizată. Motivul este că intrările în învățarea supervizată trebuie să fie înțelese foarte bine și să fie etichetate.
- **Nu are loc în timp real**, pe când cea nesupervizată are loc în timp real. Aceasta este, de asemenea, o diferență majoră între învățarea supervizată și nesupervizată.
- **Este nevoie de mult timp de calcul** pentru antrenament.
- **Dacă există cantități mari de date în dinamică, este dificil de etichetat** pentru a predefini regulile. Aceasta poate fi o adevărată provocare.

În plus, avantajele și/sau dezavantajele învățării automate supervizate depind în mare măsură de algoritmul de învățare supervizat care se utilizează.

Învățarea nesupervizată

Învățarea nesupervizată este un tip de algoritm de învățare automată care caută modele într-un set de date fără etichete preexistente. Acest tip de învățare automată necesită puțină supraveghere umană și muncă de pregătire a datelor. Deoarece învățarea nesupervizată nu se bazează pe etichete pentru a identifica modele, informațiile tind să fie mai puțin părtinitoare decât în alte forme de AI. Practic, în învățarea nesupervizată, chiar dacă nu avem etichete pentru date, avem în schimb date reale. Aceasta înseamnă că putem extrage referințe din observațiile din datele de intrare.

În cazul învățării nesupervizate există următoarele valabile:
- Nu există variabile de ieșire, ci doar un set de predictori (caracteristici) măsurați pe un eșantion de date.
- Obiectivul nu este clar: găsirea eșantioanelor care au un comportament similar / găsirea caracteristicilor care au un comportament similar / găsirea combinațiilor liniare de caracteristici care au cea mai mare variație.
- Este dificil de estimat performanța.
- Poate fi folosită ca un pas de preprocesare ajutător, înaintea aplicării învățării supervizate.

Modelele de învățare nesupervizată sunt utilizate în următoarele moduri:
- *Clustering*: acesta este procesul de găsire a asemănărilor între datele neetichetate și de grupare a acestora.
- *Asociere*: această metodă de învățare găsește relațiile între datele dintr-un anumit set.
- *Reducerea dimensionalității*: această tehnică este utilizată atunci când numărul de trăsături dintr-un set de date este prea mare. Această tehnică reduce numărul de intrări la o dimensiune mai gestionabilă, păstrând în același timp integritatea datelor.

Clustering

După cum sugerează și numele, clustering-ul implică împărțirea datelor în mai multe grupuri de valori similare. Cu alte cuvinte, obiectivul grupării este de a separa grupurile cu trăsături similare și de a uni datele în diferite grupuri. Putem spune altfel: cu cât două observații (date) sunt mai asemănătoare, cu atât este mai probabil ca acestea să se regăsească în același grup.
Clustering este o tehnică nesupervizată în care scopul este de a găsi grupuri naturale sau clustere de date într-un spațiu caracteristic și de a interpreta într-un fel datele de intrare.

Există mai mulți algoritmi de clustering în domeniul științei datelor. O abordare comună este împărțirea datelor astfel încât fiecare punct (dată) să se încadreze într-un grup, fiind similar cu alte puncte (date) din același grup, pe baza unei similitudini predefinite sau a unei metrici de distanță în spațiul caracteristic.

Pașii generali ai procesului de grupare a datelor sunt următorii:
- stabilirea datelor de intrare (opțional selectarea atributelor – *feature selection*);
- definirea unei măsuri de proximitate (vecinătate) adecvate domeniului datelor;
- gruparea propriu-zisă (*clustering*);
- abstractizarea (dacă este cazul);
- evaluarea rezultatelor.

Exemplu: Avem un număr de obiecte într-un coș (Fig. 2). Fiecare obiect are un set distinct de caracteristici (mărime, formă, culoare etc.). Mai mult, ne putem imagina că s-a trasat o sarcină de grupare pentru fiecare dintre obiectele din coș. O primă problemă este „pe ce bază se vor grupa aceste obiecte?”, iar soluția poate fi mărimea, forma sau culoarea. Pe măsură ce coșul crește și numărul de obiecte crește, sarcina de grupare devine din ce în ce mai complexă – pot exista atâtea moduri de grupare (clustering) a obiectelor câte obiecte sunt în coș!

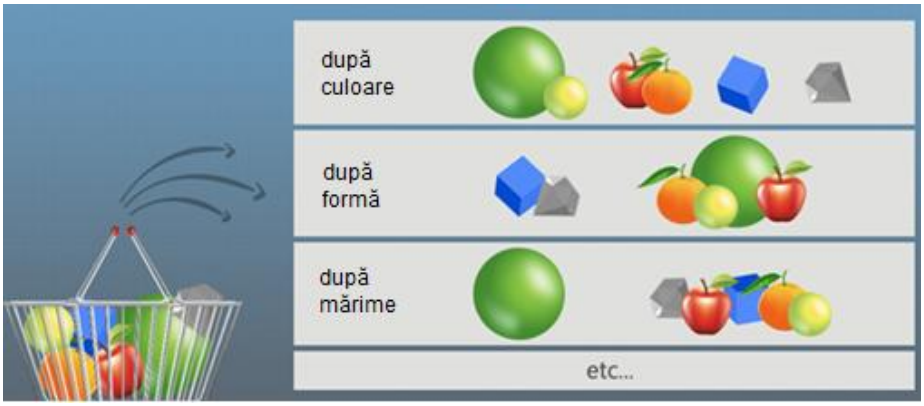


Fig. 2. Clusteringul implică gruparea obiectelor în funcție de asemănările lor.

Există mai multe tipuri de algoritmi de clustering care gestionează grupările de date, de exemplu, bazați pe centroid, densitate, distribuție, conectivitate.

Asocierea

Învățarea regulilor de asociere este o tehnică de învățare automată care este utilizată pentru a găsi modele (relații, structuri etc.) și pentru a extrage informații relevante despre aceste relații. Acest algoritm se bazează pe principiul că datele care se întâlnesc împreună într-un set de date sunt probabil asociate.

Învățând aceste modele, se vor putea oferi câteva articole clienților pe baza exemplului următor. O metodă prin care se poate descrie modul în care diferitele articole relaționează între ele este pe bază de reguli de asociere. Uneori se poate vedea această tehnică ca “Analiza coșului de cumpărături”.

Problema regulilor de asociere este definită astfel:

Fie $I = \{i_1, i_2, \ldots, i_n\}$ un set de n atribute numite item-uri.

Fie $D = \{t_1, t_2, \ldots, t_m\}$ un set de tranzacții dintr-o bază de date.

Fiecare tranzacție din D are un ID de tranzacție unic și conține un subset de articole din I.

O regulă este definită ca o implicație a formei:

$X \Rightarrow Y$

unde $X, Y \subseteq I$.

Fiecare regulă este compusă din două seturi diferite de elemente, cunoscute și sub denumirea de seturi de item-uri, X și Y, unde X este numit antecedent sau partea stângă și Y consecvent sau partea dreaptă.
Setul de articole este I = {lapte, pâine, unt, ciocolată, mere, brânză, miere}, iar în tabel este prezentată o bază de date care conține articolele precizate.
Un exemplu de regulă pentru un supermarket ar putea fi: {lapte, pâine} ⇒ {unt}, ceea ce înseamnă că, dacă se cumpără lapte și pâine, clienții cumpără și unt.

Se consideră următoarele 3 metrici:

Suport(X,Y) = Frecvența(X,Y) / N
Încredere(X,Y) = Frecvența(X,Y) / Frecvența(X)
Corelația (creșterea) = Suport(X,Y) / ((Suport(X) * Suport(Y))

Metrica *Suport* se referă la frecvența (nr. de tranzacții) de a observa X și Y împreună.
Metrica *Încredere* reprezintă raportul dintre tranzacțiile care conțin atât X cât și Y și suma totală a valorilor X prezente.
Metrica *Corelație* se referă la faptul că atunci când X este cumpărat, probabilitatea de a cumpăra Y crește de un număr de ori egal cu valoarea corespunzătoare calculată.

Exemplu:

ID tranzacție	**Produse**
1	pâine, lapte, unt, mere
2	unt, brânză
3	brânză, ciocolată
4	pâine, lapte, unt
5	lapte, pâine, miere

Suport({lapte, pâine} ⇒ {unt}) = Frecvența({lapte, pâine} ⇒ {unt}) / N = 2/5
Încredere({lapte, pâine} ⇒ {unt}) = Frecvența({lapte, pâine} ⇒ {unt}) / Frecvența(({lapte, pâine}) = 2/3

Acest lucru sugerează că untul este cumpărat în 67% din cazurile în care sunt cumpărate pâinea și laptele. În cadrul acestui set de date, pâinea și laptele sunt achiziționate în total de 3 ori, dintre care 2 constau în achiziții de unt.

Corelația({lapte, pâine} ⇒ {unt}) = Suport({lapte, pâine} ⇒ {unt})/ ((Suport({lapte, pâine} * Suport{unt}) = 2/5 / ((3/5) * (3/5)) = 1,11
Dacă valoarea Corelației este mai mare decât 1, acest lucru permite cunoașterea gradului în care aceste două apariții sunt dependente una de cealaltă și face ca aceste reguli să fie potențial utile pentru prezicerea consecințelor în seturile de date viitoare.

Avantaje:
- **Mai puțină complexitate** în comparație cu învățarea supervizată. Spre deosebire de algoritmii supervizați, în învățarea nesupervizată, nimeni nu este obligat să înțeleagă și apoi să eticheteze intrările de date.
- **Are loc în timp real**, astfel încât toate datele de intrare să fie analizate și etichetate în prezența cursanților. Acest lucru îi ajută să înțeleagă foarte bine diferite modele de învățare și sortare a datelor brute.
- **Este adesea mai ușor să se obțină date neetichetate** de la un computer decât date etichetate, care necesită intervenția unui operator. Aceasta este, de asemenea, o diferență cheie între învățarea supervizată și nesupervizată.
- **Găsește modele ascunse**: algoritmi precum gruparea și extragerea regulilor de asociere pot găsi modele și grupări interesante în seturi mari de date neetichetate.

Dezavantaje:
- **Nu este foarte precisă** cu privire la definiția sortării datelor și a rezultatelor. Acest lucru se datorează faptului că datele utilizate în învățarea nesupervizată sunt neetichetate și nu sunt cunoscute.
- **Rezultatele sunt subiective**: nu există valori obiective privind acuratețea. Utilitatea rezultatelor depinde în mare măsură de modul în care omul le interpretează. Fără date etichetate, poate fi dificil să se evalueze performanța modelelor de învățare nesupravegheată, ceea ce face dificilă evaluarea eficacității acestora.
- **Dependență ridicată de calitatea datelor:** Eficacitatea învățării nesupravegheate depinde în mare măsură de calitatea datelor de intrare. Deoarece acești algoritmi învață tipare direct din date fără supraveghere umană, orice părtinire, inconsecvență sau anomalie inerente poate duce la rezultate înșelătoare.
- **Interpretabilitate:** Rezultatele grupării pot fi uneori dificil de interpretat, mai ales atunci când se lucrează cu seturi mari de date.

Sintetizând cele două modele de învățare supervizată și nesupervizată, se pot observa principalele tipuri de abordări care pot fi utilizate în diferite aplicații (Fig. 3):

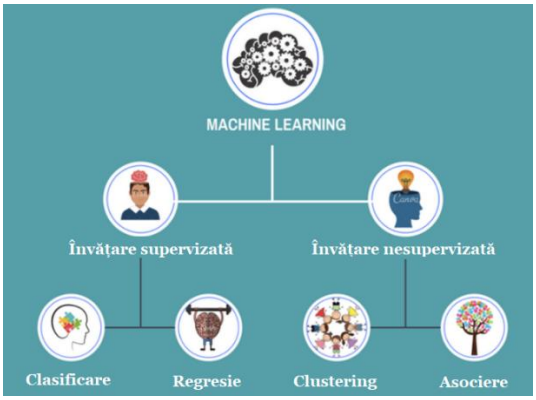


Fig. 3. Detalierea tipurilor de abordări utilizate în fiecare dintre modelele de ML.

În tabelul 2 se prezintă o serie de comparații între învățarea nesupervizată și învățarea supervizată.

Tabelul 2. Comparații între învățarea supervizată și nesupervizată

	Învățare supervizată	**Învățare nesupervizată**
Date de intrare	date de intrare etichetate	date de intrare neetichetate
Complexitate	complexitate mai mare de calcul	complexitate mai mică de calcul
Nr. de clase	cunoscut	necunoscut
Timp real	analiza datelor off-line	analiza datelor în timp real
Tipuri	două tipuri de învățare supervizată: clasificare, regresie	două tipuri de învățare supervizată: clustering, asociere
Algoritmi utilizați	- Arbori de decizie/ Arbori de regresie - KNN - Linear SVC (Support vector classifier) - Regresie logistică - Naive Bayes - Rețele neuronale - Regresie liniară - SVR (Support vector regression) - Gradient boosting	- K means clustering - Reducerea dimensionalității - Principal component analysis (PCA) - Independent component analysis (ICA) - Hierarhical clustering - Distribution models
Exemple de aplicații	- Detectarea fraudelor bancare (fraudă / non-fraudă) - Detectarea emailuri-lor spam (spam/ non-spam) - Analiza sentimentelor (fericit/ nefericit) - Prezicerea riscului unui pacient de boală (risc crescut/ risc scăzut)	- Detectarea anomaliilor (evenimentelor în rețelele de senzori, monitorizarea traficului, amenințărilor de securitate cibernetică, intruziunilor în rețea etc.) - În domeniul de marketing, atunci când o companie dorește să-și selecteze un anumit segment de clienți pentru a ajusta mai bine produsele și ofertele

Învățarea semi-supervizată

Învățarea semi-supervizată este o paradigmă de învățare care se ocupă de studiul modului în care computerele și oamenii învață în prezența atât a datelor etichetate, cât și a celor neetichetate. În mod tradițional, învățarea a fost studiată fie în paradigma nesupervizată (de exemplu: gruparea, asocierea), în care toate datele sunt neetichetate, fie în paradigma supervizată (de exemplu, clasificarea, regresia), în care toate datele sunt etichetate. Învățarea semi-supervizată constă în înțelegerea modului în care combinarea datelor etichetate și neetichetate poate schimba comportamentul de învățare și în implementarea algoritmilor care profită de o astfel de combinație. Învățarea semi-supervizată este de mare interes în învățarea automată și în extragerea datelor, deoarece poate folosi date neetichetate care pot fi ușor accesibile pentru a îmbunătăți sarcinile de învățare supervizată atunci când datele etichetate sunt mai puține, sau costisitoare.
Exemple de probleme sunt clasificarea și regresia.
Principiul de lucru este destul de simplu. În loc să se adauge etichete la întregul set de date, se parcurge mai întâi și se etichetează manual doar o mică parte a datelor ce se utilizează pentru a antrena un model, care apoi este aplicat numărului mare de date neetichetate.

Aplicații ale învățării semi-supervizată

Clasificarea textului: scopul este de a clasifica un text dat în una sau mai multe categorii predefinite. Învățarea semi-supervizată poate fi utilizată pentru a antrena un model de clasificare a textului folosind o cantitate mică de date etichetate și o cantitate mare de date text neetichetate.
Clasificarea imaginilor: scopul este de a clasifica o anumită imagine în una sau mai multe categorii predefinite. Învățarea semi-supervizată poate fi utilizată pentru a antrena un model de clasificare a imaginilor folosind o cantitate mică de date etichetate și o cantitate mare de date de imagine neetichetate.
Detectarea anomaliilor: scopul este de a detecta modele sau observații care sunt neobișnuite sau diferite de normal.
Analiza vorbirii: deoarece etichetarea fișierelor audio este o sarcină foarte intensă, învățarea semi-supravegheată este o abordare foarte naturală pentru a rezolva această problemă.
Clasificarea conținutului de internet: etichetarea fiecărei pagini web este un proces ineficace și imposibil de realizat și, prin urmare, utilizează algoritmi de învățare semi-supervizați. Chiar și algoritmul de căutare Google folosește o variantă a învățării semi-supervizate pentru a clasifica relevanța unei pagini web pentru o anumită interogare.

Cel mai mare dezavantaj al oricărui algoritm de învățare supervizată este că setul de date trebuie să fie etichetat manual de cele mai multe ori de un specialist în învățare automată. Acesta este un proces foarte costisitor, mai ales atunci când sunt disponibile volume mari de date. Dezavantajul principal al oricărei învățări nesupervizate este că spectrul său de aplicare este limitat. Pentru a contracara aceste dezavantaje, a fost introdus conceptul de învățare Semi-Supervizată. Cazurile de utilizare tipice ale unui astfel de algoritm au o proprietate comună între ele - achiziționarea datelor neetichetate este relativ ieftină, în timp ce etichetarea datelor menționate este foarte costisitoare.

Învățarea prin recompensă

Originile învățării prin recompensă pot fi observate încă din anii 1950 datorită activității psihologului B.F. Skinner. El a studiat comportamentul animalelor și a dezvoltat conceptul de condiționare operantă, care reprezintă baza învățării prin recompensă. Cu toate acestea, abia la sfârșitul anilor 1980 și la începutul anilor 1990, cercetătorii au început să aplice conceptele de învățare prin recompensă în domeniul inteligenței artificiale.
Învățarea prin recompensă devine din ce în ce mai importantă în domeniul AI, deoarece permite sistemelor să învețe din mediul lor și să-și îmbunătățească performanța în timp. Este deosebit de utilă pentru crearea de agenți inteligenți care pot interacționa și se pot adapta la mediul lor, cum ar fi roboți, jocuri și sisteme de recomandare.
Metoda de învățare prin recompensă urmărește utilizarea observațiilor adunate din interacțiunea cu mediul pentru a întreprinde acțiuni care să maximizeze recompensa sau să minimizeze riscul.
Învățarea prin recompensă este o tehnică în care modelele de învățare automată învață să ia o serie de decizii pe baza feedback-ului pe care îl primesc pentru acțiunile lor. Pentru fiecare acțiune bună, sistemul primește feedback pozitiv, iar pentru fiecare acțiune nesatisfăcătoare, primește o penalizare sau un feedback negativ. Deci, spre deosebire de învățarea automată supervizată, un model prin recompensă învață automat folosind feedback în loc de date etichetate.
În Fig. 4 este prezentată schema de bază a învățării prin recompensă. Agenții sunt auto-instruiți cu privire la mecanismele de recompensă și pedeapsă. Este vorba de a alege cea mai bună acțiune sau cale posibilă pentru a obține recompense maxime și pedepse minime prin observații într-o situație specifică. Acționează ca un semnal pentru comportamentele pozitive și negative. În esență, se construiește un agent (sau mai mulți) care poate percepe și interpreta mediul în care este plasat și, în plus, poate întreprinde acțiuni și interacționa cu acesta.

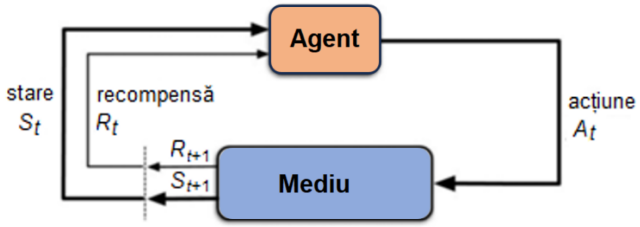


Fig. 4. Diagrama de bază a învățării prin recompensă.

Terminologii utilizate în învățarea prin recompensă

Cadrul de învățare prin recompensă este alcătuit din cinci componente principale:
1. Agent – este singurul care ia decizii și care învață;
2. Mediu – o lume fizică în care un agent învață și decide acțiunile care trebuie efectuate;
3. Acțiune – o listă de acțiuni pe care le poate efectua un agent;
4. Stare – situația actuală a agentului în mediu;
5. Recompensă – pentru fiecare acțiune selectată de către agent, mediul oferă o recompensă. De obicei, este o valoare scalară și nimic altceva decât feedback din mediul înconjurător.

Procesul de învățare prin recompensă

Procesul de învățare prin recompensă este o buclă care începe cu observarea de către agent a stării curente a mediului și se termină cu actualizarea de către agent a cunoștințelor pe baza recompensei primite.

1. Observație – agentul începe prin a observa starea curentă a mediului. Aceste informații determină cea mai bună acțiune de luat în continuare.
2. Selectarea acțiunii – pe baza stării curente a mediului, agentul selectează o acțiune de efectuat. Procesul de selecție a acțiunilor este ghidat de politica curentă a agentului, care este o funcție care mapează stările la acțiuni.
3. Calculul recompensei – după ce agentul acționează, mediul oferă un semnal de recompensă, care este o valoare scalară care indică cât de bine funcționează agentul. Agentul folosește acest semnal de recompensă pentru a-și actualiza cunoștințele și pentru a-și îmbunătăți comportamentul în timp.
4. Actualizarea stării – după ce agentul primește recompensa, își actualizează înțelegerea despre starea actuală și folosește aceste informații noi pentru a-și ghida decizia viitoare. Scopul agentului este să învețe o politică care să maximizeze recompensa cumulativă în timp.

Modul de funcționare a învățării prin recompensă

Mecanismul de acțiune din spatele învățării prin recompensă reflectă multe scenarii din lumea reală. Putem lua în considerare, de exemplu, mecanismul de dresare a animalelor de companie prin recompensă pozitivă (Fig. 5).

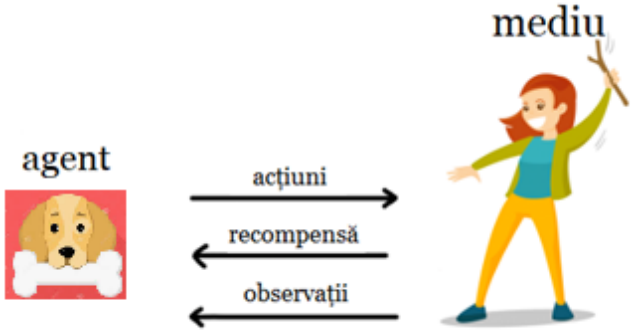


Fig. 5. Învățare prin recompensă în dresajul câinelui.

Folosind terminologia de învățare prin recompensă, scopul învățării în acest caz este de a antrena câinele (agentul) pentru a îndeplini o sarcină într-un mediu care include împrejurimile precum și stăpânul. Ne putem imagina că antrenăm un câine pentru a prinde un băț. De fiecare dată când câinele prinde bățul cu succes, i se oferă un răsfăț alimentar (de ex. un os). În cele din urmă, câinele înțelege modelul că ori de câte ori stăpânul aruncă un băț, ar trebui să-l prindă cât mai devreme pentru a obține o recompensă (un os) de la stăpân într-un timp mai scurt.

Un lucru important care trebuie reținut este că învățarea prin recompensă are nevoie de un număr mare de interacțiuni între agent și mediu pentru a colecta date pentru antrenare.

Fluxul de lucru pentru învățare prin recompensă

– Crearea mediului

Mai întâi trebuie să se definească mediul în care funcționează agentul de învățare prin recompensă, inclusiv interfața dintre agent și mediu. Mediul poate fi fie un model de simulare, fie un sistem fizic real, dar mediile simulate sunt de obicei un prim exemplu bun, deoarece sunt mai sigure și permit experimentarea.
– Definirea recompensei
Apoi, se specifică semnalul de recompensă pe care agentul îl folosește pentru a-și măsura performanța față de obiectivele sarcinii și modul în care acest semnal este calculat din mediu. Formarea recompensei poate fi dificilă și poate necesita câteva iterații pentru a o realiza corect.

– Crearea agentului
Apoi este creat agentul, care constă din politică și algoritmul de antrenare a învățării prin recompensă. Deci trebuie să urmărească:
a) Alegerea unei modalități de a reprezenta politica (cum ar fi utilizarea rețelelor neuronale sau a tabelelor de căutare).
b) Selectarea algoritmului de antrenament corespunzător. Diferite reprezentări sunt adesea legate de categoriile specifice de algoritmi de antrenament. Dar, în general, majoritatea algoritmilor moderni de învățare prin recompensă se bazează pe rețelele neuronale, deoarece sunt candidați buni pentru probleme complexe.

– Antrenarea și validarea agentului
În această etapă are loc configurarea opțiunii de antrenare (cum ar fi criteriile de oprire) și antrenarea agentului să ajusteze politica. Apoi, este necesar să se valideze politica antrenată după terminarea antrenării. Dacă este necesar, se revizuiesc alegerile de proiectare, cum ar fi semnalul de recompensă și arhitectura politicii, și se antrenează din nou.

– Implementarea politicii
În această etapă are loc implementarea politicii instruite folosind diferite toolbox-uri, în care politica este un sistem independent de luare a deciziilor.

Caracteristicile învățării prin recompensă
– Fără supervizare, doar o valoare reală sau un semnal de recompensă;
– Luarea deciziilor este secvențială;
– Timpul joacă un rol major în problemele de recompensă;
– Feedback-ul nu este prompt, ci întârziat;
– Acțiunile agentului determină datele ulterioare pe care le primește.

Algoritmi de învățare prin recompensă
Există 3 abordări pentru a implementa algoritmii de învățare prin recompensă, după cum urmează:
Bazat pe valoare – scopul principal al acestei metode este de a maximiza o funcție de valoare, în care valorile de stare (sau acțiune-stare) sunt învățate.
Bazat pe politici – permite identificarea unei strategii pentru obținerea unei recompense maxime în viitor prin posibile acțiuni efectuate în fiecare stare. Există două tipuri de metode bazate pe politici: deterministe și stohastice.
Bazat pe model – scopul este crearea unui model virtual pentru agent care să ajute să învețe să performeze în fiecare mediu specific.

Există două tipuri de învățare prin recompensă:
1. Recompensă pozitivă
Recompensa pozitivă este definită ca atunci când un eveniment are loc datorită unui comportament specific, ceea ce crește puterea și frecvența comportamentului. Are un impact pozitiv asupra comportamentului.

2. Recompensă negativă
Întărirea negativă consolidează un răspuns sau un comportament prin oprirea, eliminarea sau evitarea unui rezultat negativ ori a unui stimul aversiv. Recompensa negativă elimină o condiție neplăcută și, de asemenea, face ca un comportament să fie mai probabil.

Există mai mulți algoritmi diferiți care pot fi utilizați pentru învățarea prin recompensă, fiecare având puncte tari și puncte slabe.

- Q Learning;
- SARSA (State-Action-Reward-State-Action);
- Deep Deterministic Policy Gradient;
- A3C (Asynchronous Advantage Actor-Critic);
- PPO (Proximal Policy Optimization).

Aplicații practice ale învățării prin recompensă
– Robotică pentru automatizări industriale;
– Motoare de rezumat text, agenți de dialog (text, vorbire);
– Mașini autonome, control inteligent;
– Sistem de instruire care ar emite instrucțiuni și materiale personalizate în funcție de cerințele studenților;
– Jocuri pe calculator.